



Universidade Federal
de São João del-Rei

TMDB · MACHINE LEARNING · REGRESSÃO

Uma Análise Comparativa de Modelos para Predição da Receita de Filmes

A Comparative Analysis of Models for Movie Revenue Prediction

Gabriel Prenassi

Universidade Federal de São João del-Rei · DCOMP · 2026

Motivação e Objetivo

Por que esse problema importa?

A indústria cinematográfica opera com altos custos de produção e forte incerteza de demanda. Modelos preditivos apoiam decisões de seleção de projetos, lançamento e alocação de recursos

Recorte adotado

Predizer a receita mundial usando apenas metadados da API TMDb disponíveis antes do lançamento: orçamento, duração, idioma, gêneros e pertencimento a coleção

Objetivo Central

- Comparar diferentes modelos de regressão sob o mesmo protocolo experimental
- Avaliar desempenho global, comportamento dos erros por faixa de receita e importância dos atributos
- Identificar quais características realmente sustentam a predição da arrecadação

Base de Dados - Atributos

20.000

registros iniciais via API TMDB

6.918

filmes válidos após pré-processamento

11

atributos coletados da API

Atributo	Natureza	Descrição
ID	Identificação	Identificador único do filme na base de dados do TMDB
Título	Identificação	Título original do filme, sem tradução
Idioma original	Categórico	Código do idioma original do filme, por exemplo, en para inglês
Indicador de conteúdo adulto	Binário	Informa se o filme está marcado na base como conteúdo adulto
Vídeo	Binário	Informa se a entrada corresponde a um vídeo, como <i>trailer</i> ou clipe
Gêneros	Categórico	Lista com os gêneros associados ao filme, como ação, drama ou comédia
Situação de lançamento	Categórico	<i>Status</i> atual do lançamento, como <i>Released</i> ou <i>Post Production</i>
Duração	Numérico contínuo	Tempo de execução do filme, em minutos
Coleção	Categórico	Indica se o filme pertence a uma franquia ou coleção
Orçamento	Numérico contínuo	Estimativa do valor gasto na produção, em US\$
Receita	Numérico contínuo	Receita mundial total arrecadada, em US\$

Base de Dados - Pré-processamento

20.000

registros iniciais via API TMDB

6.918

filmes válidos após pré-processamento

6

atributos de entrada + receita como alvo

1. Coleta

1.000 requisições × 20 filmes por resposta

2. Limpeza

6.233 duplicatas removidas → 13.767 únicos

3. Filtragem - Valores faltantes

Nulos permitidos apenas em “coleção”

4. Filtragem - Variáveis numéricas válidas

Orçamento, receita e duração maiores que zero

5. Filtragem - Informações completas

Apenas filmes com gêneros disponíveis

6. Filtragem - Tipo de registro

Exclusão de vídeos, *trailers* e clipes

7. Filtragem - Status da obra

Foram mantidos somente filmes com *status* “Released”

Análise Exploratória da Base - Idiomas, Gêneros e Coleções

47 idiomas


Inglês: 5.963 filmes (≈ 86,2%)

19 gêneros


Drama (3.186) · Comédia (2.414) · Thriller (1.953)

72,5%

dos filmes sem vínculo com coleção ou franquia



Frequência por idioma original



Frequência por gênero

Análise Exploratória da Base - Duração de Filmes

110,9 min

Média

21,2 min


Desvio padrão

107 min


Mediana

5 a 254 min

Valor mínimo e máximo



Distribuição concentrada entre 90 e 120 minutos, com leve assimetria à direita



Presença de valores extremos, principalmente em durações mais altas

Análise Exploratória da Base - Distribuição do Orçamento

US\$ 33,9 mi

Média

US\$ 44,2 mi


Desvio padrão

US\$ 19 mi


Mediana

US\$ 1 a 465,4 mi

Valor mínimo e máximo



Distribuição concentrada em orçamentos baixos, com forte assimetria à direita



Presença de muitos valores extremos, principalmente em orçamentos muito altos

Análise Exploratória da Base - Distribuição da Receita

US\$ 99 mi

Média

US\$ 185,9 mi


Desvio padrão

US\$ 35,2 mi


Mediana

US\$ 1 a 2,92 bi

Valor mínimo e máximo



Distribuição concentrada em receitas baixas, com forte assimetria à direita




Presença de valores extremos associados a filmes de receita muito alta

Estratificação da Base

Por que estratificar a base?

- A receita dos filmes é muito assimétrica
- Poucos filmes concentram arrecadações muito altas
- A variável-alvo foi dividida em 5 faixas por quantis
- Cada *fold* manteve proporções semelhantes dessas faixas
- A validação cruzada se torna mais equilibrada e representativa




Estratificação por quantis - 5 faixas (~1.384 filmes cada)

Estratificação da Base

Faixas de Receita na Estratificação

Muito baixa	US\$ 1 – US\$ 7,09 mi
Baixa	US\$ 7,09 – US\$ 22,46 mi
Média	US\$ 22,46 – US\$ 52,82 mi
Alta	US\$ 52,82 – US\$ 134,08 mi
Muito alta	US\$ 134,08 – US\$ 2.923,71 mi



Estratificação por quantis - 5 faixas (~1.384 filmes cada)

Modelos Avaliados

Dummy Regressor

Linha de base: prevê valor fixo do treino. Referência mínima de desempenho

Regressão Linear

Modelo simples: testa relação linear entre atributos e receita.
Referência inicial

KNN Regressor

Baseado em vizinhos: prevê a receita por filmes semelhantes.
Depende da proximidade entre atributos

SVR

Baseado em margem: busca ajustar a receita com tolerância ao erro.
Útil para relações não lineares

Árvore / Random Forest

Baseados em árvores: capturam relações não lineares. Random Forest reduz a instabilidade

Gradient Boosting / XGBoost

Ensembles sequenciais: combinam várias árvores. Capturam interações complexas

Métricas de Avaliação

MSE

Erro quadrático médio: penaliza erros grandes. Quanto menor, melhor

RMSE

Raiz do MSE: mede o erro na mesma escala da receita. Quanto menor, melhor

MAE

Erro absoluto médio: indica o desvio médio das previsões. Menos sensível a valores extremos.

R²

Coefficiente de determinação: indica quanto da variação da receita é explicada pelo modelo. Quanto maior, melhor

Protocolo Experimental

Validação

- Validação cruzada com 10 *folds*
- Mesmas divisões usadas em todos os modelos
- Avaliação final em partes não vistas da base
- Comparação feita sob o mesmo protocolo experimental

Ajuste dos modelos

- *Grid Search* aplicado apenas no treino
- Busca por diferentes combinações de hiperparâmetros
- Seleção da melhor configuração por validação interna
- Critério de escolha: menor MSE

Perguntas de Pesquisa

QP1

Em que medida metadados estruturados podem estimar a receita mundial?

QP2

Quais regressores apresentam melhor desempenho sob o mesmo protocolo?

QP3

Como os erros se comportam ao longo das diferentes faixas de receita?

QP4

Quais atributos mais contribuem para a predição da receita?

Resultados Globais

Modelo	MSE [10 ¹⁶ US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R ²
<i>XGBoost Regressor</i>	1,39 ± 0,31	117,32 ± 12,95	58,94 ± 2,49	0,594 ± 0,060
<i>Random Forest Regressor</i>	1,44 ± 0,30	119,31 ± 12,50	59,53 ± 2,33	0,579 ± 0,068
<i>Gradient Boosting Regressor</i>	1,46 ± 0,32	120,15 ± 12,87	59,19 ± 2,67	0,571 ± 0,086
<i>Linear Regression</i>	1,51 ± 0,36	122,18 ± 14,59	63,63 ± 2,56	0,562 ± 0,054
<i>Decision Tree Regressor</i>	1,71 ± 0,32	130,44 ± 12,01	64,03 ± 1,94	0,494 ± 0,097
<i>KNN Regressor</i>	1,73 ± 0,36	130,87 ± 13,85	66,96 ± 3,60	0,497 ± 0,057
<i>Dummy Regressor</i>	3,45 ± 0,68	184,99 ± 18,95	104,67 ± 3,15	0,000 ± 0,001
<i>SVR</i>	3,86 ± 0,71	195,71 ± 18,74	86,55 ± 3,11	-0,121 ± 0,018

✓ XGBoost: menor MSE, RMSE, MAE e maior R² = 0,594


✗ SVR: R² negativo (-0,121), abaixo da linha de base em MSE/RMSE/R²

Erros por Faixa de Receita

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1.384	[US\$ 1, US\$ 7,09 mi]	26,50	-26,23	7,4%
Baixa receita	1.383	(US\$ 7,09 mi, US\$ 22,46 mi]	32,40	-31,14	11,1%
Média receita	1.384	(US\$ 22,46 mi, US\$ 52,82 mi]	31,00	-23,51	28,4%
Alta receita	1.383	(US\$ 52,82 mi, US\$ 134,08 mi]	41,33	-2,60	59,0%
Muito alta receita	1.384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	163,44	83,54	71,7%

Obs.: resíduo = receita real - receita prevista. Valores negativos indicam superestimação; valores positivos indicam subestimação

Importância dos Atributos



Importância por permutação calculada com base no MSE

① Orçamento

Atributo dominante. Reflete escala de produção e investimento associado

② Coleção / Franquia

Reconhecimento prévio da franquia e público já estabelecido

③ Duração

Característica estrutural da obra. Contribuição relevante, porém menor

④ Gênero e Idioma

Animação, Ficção Científica e inglês com importância complementar

Conclusões

Visão Geral

- Metadados estruturados do TMDb permitiram estimar parcialmente a receita mundial dos filmes
- O XGBoost Regressor obteve o melhor desempenho global
- A principal limitação ocorreu em filmes de arrecadação muito alta
- Orçamento, pertencimento a coleção e duração foram os atributos mais relevantes

Próximos passos

- Testar estratégias mais robustas para lidar com assimetria da receita e valores extremos
- Adicionar variáveis como elenco, diretor, distribuidora e período de estreia
- Incorporar sinais externos, como redes sociais, avaliações online e engajamento do público