

ARTIGO DE PESQUISA/RESEARCH PAPER

Uma Análise Comparativa de Modelos para Predição da Receita de Filmes

A Comparative Analysis of Models for Movie Revenue Prediction

Gabriel Prenassi  [Universidade Federal de São João del-Rei | prenassigabriel@aluno.ufsj.edu.br]

Departamento de Ciência da Computação, Universidade Federal de São João del-Rei, BR-494, s/n, Campus CTan, São João del-Rei, MG, 36301-360, Brasil.

Resumo. Este trabalho investiga a predição da receita mundial de filmes a partir de metadados estruturados extraídos da API pública do TMDB, considerando cenários de previsão ainda compatíveis com o período pré-lançamento. A análise foi organizada em dois níveis de informação. No primeiro, mais restrito, foram utilizados atributos como orçamento, duração, idioma original, gêneros e pertencimento a uma coleção. No segundo, ainda preliminar, mas mais informado, também foram incorporados metadados relacionados ao período de estreia, à direção, ao elenco principal e às empresas de produção. Em ambos os casos, diferentes regressores foram comparados sob o mesmo protocolo experimental, com avaliação por MSE, RMSE, MAE e R^2 , além de análises por faixa de receita, importância dos atributos e estratégias específicas para lidar com a assimetria da variável-alvo. Os resultados mostraram que, no cenário preliminar mais restrito, o *XGBoost Regressor* apresentou o melhor desempenho global, com RMSE de US\$ 117,32 milhões e $R^2 = 0,594$. A análise dos erros indicou maior dificuldade nas faixas superiores de arrecadação, especialmente entre os filmes de muito alta receita, enquanto a importância dos atributos destacou orçamento, pertencimento a uma coleção e duração. Ao ampliar o conjunto de informações pré-lançamento com novos atributos do TMDB, o melhor resultado global melhorou para RMSE de US\$ 111,66 milhões e $R^2 = 0,630$. Por fim, entre as estratégias adicionais avaliadas para a assimetria da receita, um pipeline híbrido com combinação ponderada entre especialistas por faixa alcançou o melhor resultado prático do estudo, com RMSE de US\$ 108,62 milhões e $R^2 = 0,650$.

Abstract. This work investigates worldwide movie revenue prediction using structured metadata extracted from the public TMDB API, focusing on forecasting settings that remain compatible with the pre-release period. The analysis was organized into two information levels. In the first, more restricted one, attributes such as budget, runtime, original language, genres, and collection membership were used. In the second, still preliminary but more informed one, the models also incorporated metadata related to release timing, director, top-billed cast, and production companies. In both settings, different regressors were compared under the same experimental protocol, using MSE, RMSE, MAE, and R^2 , together with revenue-band error analysis, attribute importance analysis, and specific strategies to address target asymmetry. The results showed that, in the more restricted preliminary setting, the *XGBoost Regressor* achieved the best global performance, with RMSE of US\$ 117.32 million and $R^2 = 0.594$. Error analysis indicated greater difficulty in the upper revenue bands, especially for very high-grossing films, while attribute importance highlighted budget, collection membership, and runtime. When the pre-release information set was expanded with new TMDB attributes, the best global result improved to RMSE of US\$ 111.66 million and $R^2 = 0.630$. Finally, among the additional strategies evaluated for revenue asymmetry, a hybrid pipeline based on a probability-weighted combination of revenue-band specialists achieved the best practical result of the study, with RMSE of US\$ 108.62 million and $R^2 = 0.650$.

Palavras-chave: Aprendizado de máquina, Regressão, Predição de receita, Filmes, TMDB

Keywords: Machine learning, Regression, Revenue prediction, Movies, TMDB

Recebido/Received: DD Month YYYY • Aceito/Accepted: DD Month YYYY • Publicado/Published: DD Month YYYY

1 Introdução

A predição da receita de filmes é um problema relevante no contexto da indústria cinematográfica, que se caracteriza por altos custos de produção, forte incerteza de demanda e grande heterogeneidade entre obras de baixo, médio e alto desempenho comercial [Ghiassi *et al.*, 2015; Sharda and Delen, 2006; Ahmad *et al.*, 2020b]. Mesmo em projetos com investimentos expressivos, a arrecadação final permanece difícil de antecipar, o que torna modelos preditivos potencialmente úteis para apoiar decisões de desenvolvimento, seleção de projetos, planejamento de lançamento e alocação de recursos [Lash and Zhao, 2016; Quader *et al.*, 2017; Ghiassi *et al.*, 2015].

A literatura mostra que essa previsão pode se apoiar em

diferentes tipos de evidência. Estudos clássicos destacam atributos intrínsecos aos filmes, como orçamento, duração, gênero, classificação indicativa e pertencimento a sequências [Ghiassi *et al.*, 2015; Sharda and Delen, 2006]. Outros trabalhos também consideram fatores ligados ao lançamento e à distribuição, como concorrência no período de estreia e quantidade de salas de exibição [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Kim *et al.*, 2015]. Em abordagens mais recentes, surgem ainda sinais derivados de plataformas *online*, como menções em redes sociais, comentários sobre *trailers* e avaliações de usuários, além de informações multimodais obtidas de materiais promocionais [Ahmad *et al.*, 2020a; Quader *et al.*, 2017; Kim *et al.*, 2015; Madongo and Zhongjun, 2023; Zhou *et al.*, 2019]. Em conjunto, esses

estudos indicam que o desempenho comercial dos filmes pode ser modelado a partir de múltiplas fontes de informação [Mammadov *et al.*, 2025; Ahmad *et al.*, 2020b].

Entretanto, nem todas essas fontes estão disponíveis no mesmo momento do ciclo de vida de um filme. Quando o interesse está em apoiar decisões anteriores à estreia, a disponibilidade temporal dos atributos passa a ser um aspecto metodológico central. Nesse cenário, sinais consolidados de recepção do público ou variáveis observadas após o lançamento deixam de ser adequados, e ganham importância os metadados estruturados que já descrevem a obra durante seu planejamento e posicionamento comercial. Esse recorte é particularmente relevante porque, mesmo sem recorrer a informações pós-lançamento, o conjunto de atributos disponíveis tende a se expandir à medida que a produção avança.

Com base nessa motivação, este trabalho investiga a predição da receita mundial de filmes a partir de dados extraídos da API pública do *The Movie Database*¹ (TMDB), plataforma que disponibiliza metadados estruturados sobre produções audiovisuais. A proposta não se limita a comparar modelos de regressão em um único conjunto fixo de atributos. Em vez disso, o estudo acompanha uma progressão natural de informação pré-lançamento. Em um primeiro nível, mais restrito, são considerados atributos estruturais mais imediatos, como orçamento, duração, idioma original, gêneros e pertencimento a coleção. Em um segundo nível, ainda compatível com o período pré-lançamento, mas mais informado, também passam a ser incorporadas variáveis ligadas ao período de estreia, à direção, ao elenco principal e às empresas de produção.

Essa organização permite analisar não apenas quais modelos funcionam melhor, mas também como a qualidade preditiva evolui quando a caracterização do filme se torna mais rica. Além disso, o estudo examina em que medida a assimetria da variável-alvo e a heterogeneidade entre faixas de arrecadação afetam o desempenho dos modelos, motivando a avaliação de estratégias adicionais, como funções de perda robustas e *pipelines* com especialistas por faixa de receita. Assim, a tarefa é formulada como um problema de regressão supervisionada, no qual a receita mundial arrecadada por cada filme é estimada a partir dos atributos disponíveis antes da estreia. A investigação é orientada por três perguntas de pesquisa que acompanham a progressão metodológica do artigo:

- QP1.** Até que ponto metadados estruturados disponíveis antes da estreia permitem prever a receita mundial dos filmes, e que limitações aparecem nesse processo quando se observam o desempenho global, a distribuição dos erros e a importância dos atributos?
- QP2.** O que muda no desempenho, na distribuição dos erros e nos atributos mais relevantes quando o filme passa a ser descrito por um conjunto pré-lançamento mais informado de metadados do TMDB?
- QP3.** No cenário preliminar mais informado, estratégias específicas para a assimetria da receita e para a heterogeneidade entre faixas de arrecadação conseguem superar o melhor regressor global?

Para responder a essas questões, o trabalho é organizado em etapas encadeadas. Primeiro, diferentes regressores são comparados a uma linha de base simples no cenário preliminar mais restrito, com avaliação por validação cruzada e métricas como MSE, RMSE, MAE e R^2 . Em seguida, esse primeiro resultado é aprofundado por meio da análise dos erros por faixa de receita e da importância dos atributos do melhor modelo. Depois, o conjunto de dados é enriquecido com novos metadados do TMDB ainda compatíveis com o período pré-lançamento, e a mesma lógica de comparação e diagnóstico é repetida em um cenário mais informado. Por fim, são investigadas estratégias voltadas especificamente ao tratamento da assimetria da variável-alvo, incluindo perdas robustas, especialistas por faixa de arrecadação e *pipelines* híbridos de classificação e regressão.

Com esse desenho experimental, o artigo procura avançar em duas frentes complementares: entender o alcance preditivo de metadados estruturados disponíveis antes da estreia e verificar como diferentes decisões de modelagem respondem à forte concentração de erros nos filmes de maior arrecadação. Como análise complementar, também são examinados os efeitos da transformação logarítmica da variável-alvo, a fim de verificar se a compressão dos valores extremos altera as conclusões obtidas na escala original da receita. Os resultados dessa avaliação adicional são apresentados no Apêndice A.

2 Trabalhos Relacionados

A predição do desempenho financeiro de filmes tem sido investigada a partir de diferentes formulações, como estimativa de receita, previsão de lucratividade e classificação de sucesso comercial [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Ghiassi *et al.*, 2015; Sharda and Delen, 2006]. Embora esses estudos variem quanto à variável-alvo e aos métodos utilizados, é comum que explorem atributos relacionados à própria obra, como gênero, orçamento, duração, elenco e pertencimento a sequências, além de fatores associados ao lançamento e à distribuição, como período de estreia, número de salas de exibição e concorrência com outros filmes [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Kim *et al.*, 2015]. Assim, a literatura indica que o desempenho comercial de filmes pode ser analisado a partir de diferentes fontes de informação, dependendo do momento em que a previsão é realizada e dos dados disponíveis para a modelagem.

Entre os trabalhos voltados a previsões antes do lançamento ou em fases iniciais, há estudos que utilizam principalmente atributos conhecidos antes da consolidação da recepção do público. O sucesso de bilheteria já foi tratado como uma tarefa de classificação em faixas de desempenho, considerando características como gênero, classificação indicativa, presença de sequência, efeitos especiais, competição e número de telas [Sharda and Delen, 2006]. A previsão de receita em pré-produção também foi investigada a partir de variáveis como orçamento, gastos de publicidade pré-lançamento, duração e sazonalidade [Ghiassi *et al.*, 2015]. De forma semelhante, a previsão de lucratividade em estágios iniciais foi abordada por

¹Disponível em: <https://www.themoviedb.org/>

meio da combinação de informações sobre participantes, conteúdo e momento de lançamento [Lash and Zhao, 2016]. Esses trabalhos mostram que atributos disponíveis antes da resposta efetiva do público podem fornecer indícios relevantes sobre o potencial comercial de uma produção, embora utilizem diferentes conjuntos de dados, variáveis de entrada e objetivos preditivos.

Outra linha de pesquisa busca ampliar a capacidade preditiva dos modelos por meio de sinais gerados em plataformas *online*. Dados de redes sociais já foram utilizados na previsão de bilheteria, indicando que manifestações do público podem contribuir para estimar o desempenho comercial [Kim *et al.*, 2015]. Comentários em *trailers* no *YouTube* também foram explorados para identificar sinais de interesse do público e prever receita [Ahmad *et al.*, 2020a]. Além disso, outros estudos combinam fontes como *IMDb*, *Rotten Tomatoes*, *Box Office Mojo* e *Metacritic*, incorporando atributos disponíveis antes e depois do lançamento [Quader *et al.*, 2017]. Essas abordagens evidenciam que comentários, avaliações e medidas de engajamento podem complementar os metadados tradicionais, mas dependem de exposição prévia ao público ou de informações que nem sempre estão disponíveis em fases iniciais de planejamento.

Mais recentemente, também foram exploradas abordagens com dados multimodais e métodos voltados à interpretação dos modelos. Redes neurais profundas multimodais foram utilizadas para combinar metadados dos filmes com informações visuais extraídas de pôsteres [Zhou *et al.*, 2019]. Outra abordagem investigou a predição de receita a partir da combinação entre metadados e atributos visuais extraídos de pôsteres, utilizando aprendizado profundo e transferência de aprendizado [Madongo and Zhongjun, 2023]. Além disso, a previsão de sucesso de bilheteria foi analisada com técnicas de inteligência artificial explicável, buscando identificar fatores associados à lucratividade [Mammadov *et al.*, 2025]. Esses estudos ampliam o conjunto de evidências usado na predição, mas também dependem de fontes adicionais ou representações mais complexas, como imagens, sinais de engajamento e técnicas específicas de interpretação.

Considerando esse panorama, o presente trabalho adota um recorte voltado ao período pré-lançamento e centrado em metadados estruturados. Em vez de recorrer a comentários, avaliações, sinais de engajamento ou outras evidências que dependem de exposição prévia do filme ao público, a análise parte de atributos já disponíveis na caracterização inicial das obras, como orçamento, duração, idioma original, gêneros e pertencimento a coleção. Em seguida, esse mesmo recorte é ampliado com novas informações também obtidas antes da estreia, ligadas ao período de lançamento, à direção, ao elenco principal e às empresas de produção. Com isso, o artigo passa a examinar dois níveis de informação ainda compatíveis com uma etapa preliminar de decisão: um mais restrito e outro mais informado.

Esse enquadramento aproxima a tarefa de situações em que ainda se busca estimar o potencial comercial de um filme sem recorrer a sinais posteriores de recepção do público. Ao mesmo tempo, a revisão da literatura ajuda a justificar as duas frentes que estruturam os experimentos do

artigo. A primeira consiste em verificar como o desempenho evolui quando a descrição pré-lançamento do filme se torna mais rica, mantendo o mesmo protocolo de modelagem e avaliação. A segunda decorre da própria heterogeneidade observada no problema: se diferentes trabalhos já abordaram a previsão tanto como regressão quanto em termos de faixas de desempenho, torna-se natural investigar, neste estudo, se estratégias específicas para a assimetria da receita e para as diferentes faixas de arrecadação podem produzir ganhos adicionais de predição.

3 Fundamentação Teórica

O aprendizado de máquina é uma área da inteligência artificial voltada ao desenvolvimento de métodos capazes de identificar padrões em dados e utilizá-los para realizar previsões, classificações ou outras formas de inferência [James *et al.*, 2023; Murphy, 2022]. Em problemas de aprendizado supervisionado, os modelos são treinados a partir de exemplos nos quais as variáveis de entrada estão associadas a uma saída conhecida, buscando generalizar essa relação para novos dados [James *et al.*, 2023].

Neste trabalho, o problema é formulado como uma tarefa de regressão, pois o objetivo é estimar a receita mundial dos filmes a partir de atributos descritivos e financeiros. Como a variável-alvo corresponde a um valor numérico contínuo, a regressão busca estimar valores contínuos a partir dos atributos de entrada, diferentemente de problemas de classificação, nos quais a saída pertence a um conjunto discreto de classes [James *et al.*, 2023].

3.1 Modelos de regressão

Considerando a formulação do problema como regressão, foram selecionados modelos com diferentes níveis de complexidade, tomando como base algoritmos recorrentes na literatura de predição de receita, popularidade e desempenho comercial de filmes [Udandarao and Gupta, 2024; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. A comparação parte de linhas de base simples e avança até métodos mais flexíveis, permitindo observar em que medida o aumento de complexidade contribui para capturar padrões associados à arrecadação dos filmes. Além dos modelos preditivos propriamente ditos, utiliza-se o *Dummy Regressor* como referência mínima de desempenho, pois esse modelo não aprende relações entre os atributos e a variável-alvo e produz estimativas fixas, como a média ou a mediana observada no conjunto de treinamento.

Entre os modelos mais simples, a Regressão Linear é utilizada como referência por buscar uma relação linear entre os atributos de entrada e a receita. Diferentemente do *Dummy Regressor*, esse modelo incorpora efetivamente as variáveis explicativas no processo de predição, permitindo verificar se uma estrutura linear já é suficiente para representar parte do comportamento da variável-alvo. Modelos lineares aparecem em estudos de predição de receita de filmes e são usados como ponto de comparação para abordagens mais flexíveis [Udandarao and Gupta, 2024; Ahmad *et al.*, 2020b].

Em seguida, são avaliados modelos com estratégias distintas de predição, como o *KNN Regressor* e o *SVR*. O *KNN Regressor* estima a receita com base na

similaridade entre instâncias, partindo da ideia de que filmes com características semelhantes tendem a apresentar comportamentos comerciais próximos. Modelos baseados em *KNN* aparecem em estudos de predição de receita e popularidade de filmes [Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. Já o *SVR* adapta as máquinas de vetores de suporte para regressão, buscando ajustar as previsões de modo a controlar os desvios em relação aos valores observados. Máquinas de vetores de suporte também são recorrentes na literatura de predição de receita de filmes [Ahmad *et al.*, 2020b].

Para capturar relações não lineares, também são considerados modelos baseados em árvores. A Árvore de Decisão divide o espaço dos atributos em regiões e realiza previsões a partir dessas divisões, permitindo representar interações mais complexas entre as variáveis. Árvores de decisão são utilizadas em estudos de predição de receita, popularidade ou sucesso de filmes [Udandara and Gupta, 2024; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. A *Random Forest*, por sua vez, combina várias árvores treinadas sobre diferentes amostras dos dados, reduzindo a instabilidade típica de uma única árvore e produzindo estimativas mais robustas. Esse modelo também aparece em estudos comparativos sobre predição de desempenho de filmes [Udandara and Gupta, 2024; Abidi *et al.*, 2020].

Por fim, são avaliados métodos de *ensemble* baseados em *boosting*, como *Gradient Boosting* e *XGBoost*. Nessa abordagem, vários modelos simples, geralmente árvores de decisão rasas, são treinados de forma sequencial, de modo que cada novo ajuste procure reduzir erros acumulados nas etapas anteriores. Como resultado, a predição final passa a refletir a combinação progressiva dessas correções, o que favorece a captura de relações não lineares e interações entre atributos. Esse tipo de estratégia é particularmente relevante em bases tabulares heterogêneas, como a utilizada neste trabalho, descrita na Subseção 4.1. *Gradient Boosting* e *XGBoost* aparecem em estudos de predição de receita e popularidade de filmes, sendo comparados com modelos como Regressão Linear, Árvore de Decisão e *Random Forest* [Udandara and Gupta, 2024; Abidi *et al.*, 2020].

3.2 Métricas e procedimentos de avaliação

Assim como na seleção dos modelos, a escolha das métricas de avaliação considera medidas recorrentes na literatura de predição de receita, popularidade e desempenho comercial de filmes [Udandara and Gupta, 2024; Gupta *et al.*, 2023; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. Como o problema é tratado como regressão, essas métricas quantificam a diferença entre os valores reais e os valores previstos, permitindo avaliar o quanto as estimativas dos modelos se aproximam da receita observada. Como as previsões são avaliadas na escala original da receita, métricas como MAE e RMSE permanecem diretamente interpretáveis em termos monetários, inclusive nos experimentos complementares em que o treinamento utiliza a transformação logarítmica e as previsões são posteriormente reconvertidas para dólares. Considerando n instâncias, em que y_i representa o valor real da receita e $\hat{y}_i$ representa o valor previsto pelo modelo, uma das métricas adotadas é o Erro Absoluto Médio, ou *Mean*

Absolute Error (MAE):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (1)$$

O MAE corresponde à média das diferenças absolutas entre valores reais e previstos. Por estar na mesma unidade da variável-alvo, essa métrica permite interpretar diretamente o erro médio das previsões em termos monetários. Além disso, como considera os erros em valor absoluto, o MAE fornece uma medida geral da magnitude dos desvios, sem indicar se o modelo tende a superestimar ou subestimar a receita.

Também é considerado o Erro Quadrático Médio, ou *Mean Squared Error* (MSE), que calcula a média dos erros ao quadrado e penaliza mais fortemente erros de maior magnitude. Essa métrica também aparece em avaliações de erro preditivo nesse domínio [Gupta *et al.*, 2023; Ahmad *et al.*, 2020b]:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2)$$

Por elevar os erros ao quadrado, o MSE atribui maior peso a grandes desvios entre a receita real e a prevista. Essa característica é relevante neste trabalho, pois a análise exploratória da base de dados, apresentada na Subseção 4.3, evidencia que a receita dos filmes apresenta alta variabilidade e presença de valores extremos. Assim, modelos que cometem erros muito elevados em filmes de grande arrecadação tendem a ser mais penalizados por essa métrica.

A Raiz do Erro Quadrático Médio, ou *Root Mean Squared Error* (RMSE), corresponde à raiz quadrada do MSE e mantém a interpretação do erro na mesma unidade da variável-alvo. Essa métrica é recorrente em trabalhos de regressão para predição de receita, popularidade ou desempenho de filmes [Gupta *et al.*, 2023; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3)$$

O RMSE combina duas propriedades importantes: mantém a sensibilidade a grandes erros, herdada do MSE, e permite interpretar o resultado na mesma escala da receita. Por esse motivo, é útil para comparar modelos em cenários nos quais erros elevados são especialmente importantes, como na predição de filmes com arrecadação muito acima do comportamento médio da base.

Além das métricas de erro, o coeficiente de determinação, representado por R^2 , é adotado para avaliar a qualidade do ajuste dos regressores, como ocorre em estudos de predição de receita de filmes [Udandara and Gupta, 2024]. Considerando $\bar{y}$ como a média dos valores reais, o R^2 é definido por:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (4)$$

Diferentemente das métricas de erro, em que valores menores indicam melhor desempenho, o R^2 mede a proporção da variabilidade da variável-alvo explicada

pelo modelo. Valores mais próximos de 1 indicam maior capacidade explicativa, enquanto valores próximos ou inferiores a 0 indicam desempenho baixo em relação a uma estratégia simples baseada na média dos valores observados. Assim, o uso conjunto de MAE, MSE, RMSE e R^2 permite avaliar os modelos sob perspectivas complementares: magnitude média dos desvios, penalização de grandes erros, interpretação direta na escala monetária da receita e qualidade geral do ajuste.

Embora o problema central do trabalho seja de regressão, os experimentos híbridos introduzem uma etapa intermediária em que cada filme é classificado em uma faixa de receita antes da estimativa monetária final. Essa classificação serve para definir qual regressor especialista será usado depois. Assim, avaliar o encaminhamento entre especialistas significa avaliar quão bem essa etapa consegue escolher o especialista mais adequado para cada filme.

A principal métrica classificatória adotada nesse contexto é o *macro-F1*. Para cada faixa k , calcula-se primeiro um valor $F1_k$, que combina *precision* e *recall* dessa faixa. Em seguida, calcula-se a média simples desses valores entre as K faixas de receita:

$$F1_k = 2 \cdot \frac{P_k R_k}{P_k + R_k}, \quad \text{macro-F1} = \frac{1}{K} \sum_{k=1}^K F1_k, \quad (5)$$

em que P_k representa o *precision* da faixa k e R_k seu *recall*. Como cada faixa entra com o mesmo peso nessa média, o *macro-F1* é útil para verificar se o classificador mantém desempenho equilibrado ao longo de toda a distribuição, e não apenas nas faixas mais frequentes ou mais fáceis.

Como diagnósticos complementares, também se observa a proporção de filmes encaminhados para a faixa correta, para uma faixa vizinha e o nível de confiança associado a essa decisão. Em conjunto, esses indicadores ajudam a interpretar se a etapa classificatória fornece informação suficientemente útil para sustentar a predição final da receita.

3.3 Interpretação dos erros e importância dos atributos

Além das métricas quantitativas agregadas, a análise dos erros de predição permite observar o comportamento dos modelos sob outras perspectivas. Em tarefas de regressão, os resíduos correspondem à diferença entre os valores reais e os valores previstos, permitindo identificar padrões de superestimação ou subestimação [James *et al.*, 2023]. Quando o resíduo é definido como *real* – *predito*, valores negativos indicam que o modelo previu uma receita maior que a observada, enquanto valores positivos indicam que a receita foi subestimada. Já os erros absolutos permitem avaliar a magnitude dos desvios cometidos pelo modelo, independentemente da direção do erro.

No contexto da predição de receita de filmes, essa leitura é especialmente relevante devido à alta variabilidade da variável-alvo, aspecto também observado na base utilizada neste estudo, conforme apresentado na Subseção 4.3. Essa variabilidade faz com que filmes de diferentes níveis de arrecadação possam apresentar dificuldades distintas para os modelos, tornando útil examinar os erros também por faixas

de receita definidas ao longo da distribuição da variável-alvo [Ahmad *et al.*, 2020b; Ghiassi *et al.*, 2015].

A interpretação dos modelos também pode ser complementada pela análise da importância dos atributos. Uma técnica utilizada para esse fim é a *Permutation Feature Importance*, que estima a relevância de uma variável a partir da queda de desempenho observada quando seus valores são embaralhados. De forma geral, calcula-se primeiro o desempenho do modelo com os dados originais. Em seguida, os valores de um atributo são permutados entre as instâncias, rompendo sua associação com a variável-alvo, enquanto os demais atributos permanecem inalterados. Se essa alteração provoca queda expressiva no desempenho, entende-se que o atributo possui maior importância para as predições. Essa técnica é útil para inspecionar modelos preditivos, especialmente quando se deseja compreender melhor quais características efetivamente sustentam a estimativa da receita em modelos menos transparentes. Essa preocupação com interpretabilidade também aparece em estudos recentes sobre previsão de sucesso de bilheteria com técnicas de inteligência artificial explicável [Mammadov *et al.*, 2025].

3.4 Assimetria da variável-alvo e modelagem por faixas

Como será visto na Subseção 4.3, a variável-resposta da base analisada neste trabalho não se distribui de forma equilibrada ao longo de toda a amostra. Há muitos filmes concentrados em níveis mais baixos de arrecadação e um conjunto menor de casos muito acima da média. Nessa situação, ajustar um único modelo com base em erro quadrático pode tornar o processo de estimação excessivamente sensível aos maiores desvios, já que erros muito altos recebem peso desproporcional no MSE. Por isso, faz sentido investigar funções de perda menos sensíveis a erros extremos, como erro absoluto e variantes suaves do tipo Huber e *Pseudo-Huber*, que atenuam a influência de observações extremas sem ignorar completamente a magnitude do erro [James *et al.*, 2023; Murphy, 2022].

Outra possibilidade é reconhecer que diferentes regiões da variável-alvo podem obedecer a regimes preditivos distintos. Em vez de ajustar apenas um regressor global para toda a distribuição, pode-se dividir os exemplos em faixas de receita mais homogêneas e treinar especialistas locais para cada uma delas. Esse raciocínio se torna particularmente plausível quando a análise dos resíduos sugere que filmes de baixa, média e alta arrecadação não apresentam o mesmo padrão de erro [Ghiassi *et al.*, 2015; Ahmad *et al.*, 2020b]. Em termos conceituais, um cenário *oracle* mede o limite superior dessa especialização quando a faixa correta já é conhecida, enquanto cenários aplicáveis na prática exigem algum mecanismo capaz de inferir, a partir dos atributos de entrada, qual especialista deve contribuir para a predição final.

Essa escolha do especialista pode ser implementada de forma dura ou suave. Na forma dura, um classificador seleciona uma única faixa e apenas o especialista correspondente é utilizado. Na forma suave, as probabilidades previstas para cada faixa são usadas para combinar ponderadamente as saídas de todos os especialistas, o que tende a ser mais estável em observações

próximas às fronteiras entre faixas adjacentes. Dessa forma, a estratégia híbrida entre classificação e regressão pode ser entendida como uma tentativa de explorar explicitamente a heterogeneidade da variável-alvo: a classificação organiza o espaço da resposta em regimes, e a regressão estima o valor contínuo dentro ou entre esses regimes.

Em conjunto, esses conceitos oferecem a base analítica do artigo. A seção seguinte mostra como eles foram operacionalizados no estudo por meio da construção de dois níveis de informação pré-lançamento, de um protocolo comum de validação e de experimentos adicionais voltados especificamente à assimetria da receita.

4 Metodologia Experimental

Esta seção descreve como o estudo foi organizado para acompanhar uma progressão de informação ainda compatível com o período pré-lançamento. Primeiro, é definido o conjunto de filmes analisado e construído o cenário preliminar mais restrito, formado por metadados estruturais mais imediatos sobre os filmes. Em seguida, esse cenário é caracterizado por análise exploratória. Depois, o trabalho incorpora novos metadados do TMDB sobre calendário de estreia, direção, elenco principal e empresas de produção, compondo um cenário preliminar mais informado. Com os dois níveis de informação definidos, estabelece-se um protocolo comum de avaliação para garantir comparabilidade direta entre os resultados. Por fim, são descritos os experimentos adicionais voltados à assimetria da receita, sempre preservando o mesmo conjunto de filmes e as mesmas divisões de validação.

4.1 Base de dados e organização da análise

A base de dados utilizada neste trabalho foi construída a partir de consultas à API pública do TMDB. Na coleta inicial, foram realizadas 1.000 requisições, cada uma retornando 20 filmes, o que resultou em 20.000 registros brutos. Essas consultas forneceram informações estruturadas sobre cada obra, incluindo atributos de identificação, características descritivas e dados financeiros. A Tabela 1 resume os atributos originalmente coletados nessa etapa inicial, que serviram de ponto de partida para a construção do primeiro cenário analisado no artigo.

No problema de regressão considerado, a variável-alvo é a receita mundial do filme. Como variáveis de entrada, parte-se de metadados estruturados da própria obra, como idioma original, indicador de conteúdo adulto, gêneros, pertencimento a uma coleção, duração e orçamento. Embora a base seja composta por filmes já lançados, o recorte metodológico do trabalho interpreta essas variáveis como informações que poderiam estar disponíveis, ainda que com diferentes níveis de maturidade, antes da estreia. Essa decisão é central para o artigo, pois permite discutir a predição da receita sem recorrer a sinais posteriores de recepção do público.

4.2 Definição do conjunto de filmes analisado

Partindo da base bruta descrita na subseção anterior, a definição do conjunto de filmes analisado teve como

Table 1. Descrição dos atributos coletados da base de dados do TMDB

Atributo	Descrição
ID (identificação)	Identificador único do filme na base de dados do TMDB.
Título (identificação)	Título original do filme, sem tradução.
Idioma original (categórico)	Código do idioma original do filme, por exemplo, <i>en</i> para inglês.
Indicador de conteúdo adulto (binário)	Informa se o filme está marcado na base como conteúdo adulto.
Vídeo (binário)	Informa se a entrada corresponde a um vídeo, como <i>trailer</i> ou clipe.
Gêneros (categórico)	Lista com os gêneros associados ao filme, como <i>ação</i> , <i>drama</i> ou <i>comédia</i> .
Situação de lançamento (categórico)	<i>Status</i> atual do lançamento, como <i>Released</i> ou <i>Post Production</i> .
Duração (numérico contínuo)	Tempo de execução do filme, em minutos.
Coleção (categórico)	Indica se o filme pertence a uma franquia ou coleção.
Orçamento (numérico contínuo)	Estimativa do valor gasto na produção, em US\$.
Receita (numérico contínuo)	Receita mundial total arrecadada, em US\$.

objetivo estabelecer quais obras seriam mantidas em todos os experimentos subsequentes. Dos 20.000 registros inicialmente recuperados, 6.233 correspondiam a duplicatas. Após manter apenas um exemplar de cada obra, a base passou a conter 13.767 filmes únicos. Em seguida, foram inspecionados os valores faltantes, admitindo-se ausência apenas no atributo referente ao pertencimento a coleção, uma vez que a própria API pode retornar valor nulo para filmes sem vínculo com franquias ou coleções.

Depois disso, foi aplicada uma filtragem com foco em coerência analítica e comparabilidade entre os experimentos. Foram preservados apenas filmes com valores maiores que zero para orçamento, receita e duração, garantindo a validade dessas variáveis numéricas. Também foram mantidos somente registros com lista não vazia de gêneros, removidas entradas classificadas como vídeo, tais como *trailers* e clipes, e mantidas apenas obras com *status* “*Released*”. Ao final desse processo, o conjunto de filmes analisado passou a ser composto por 6.918 títulos.

Esse conjunto de filmes é a referência comum de todo o trabalho. A partir dele foi gerada a versão processada do cenário preliminar mais restrito, com 73 colunas, utilizada na primeira rodada de comparação entre regressores. Mais adiante, os mesmos 6.918 filmes foram enriquecidos com novos metadados do TMDB, produzindo a versão processada do cenário preliminar mais informado. Assim, a diferença entre os cenários não está nas obras analisadas, mas no nível de informação disponível sobre cada uma delas.

4.3 Caracterização do cenário preliminar mais restrito

Após a definição do conjunto de filmes analisado, foi realizada uma análise exploratória com dois objetivos complementares. O primeiro foi descrever a distribuição dos atributos que sustentam o cenário preliminar mais restrito. O segundo foi identificar propriedades da variável-alvo e dos preditores que justificassem escolhas posteriores do protocolo experimental, especialmente a estratificação por

faixas de receita e a investigação específica da assimetria da arrecadação.

No que se refere ao idioma original, a base final reúne filmes em 47 idiomas diferentes. A Figura 1 apresenta os 20 mais frequentes e evidencia forte predominância do inglês, presente em 5.963 filmes, o que corresponde a aproximadamente 86,2% da base. Em seguida, aparecem o francês, com 243 filmes, e o hindi, com 108. Esse padrão indica concentração linguística elevada, mas ainda preserva diversidade suficiente para justificar a manutenção do atributo na modelagem.




Figure 1. Frequência dos idiomas originais presentes na base de dados

Os gêneros também apresentam comportamento relevante para a caracterização inicial dos filmes. Como uma mesma obra pode pertencer a múltiplas categorias, a soma das frequências ultrapassa o total de registros da base. Ao todo, foram identificados 19 gêneros distintos. A Figura 2 mostra que *Drama*, *Comedy*, *Thriller* e *Action* são os mais frequentes, com 3.186, 2.414, 1.953 e 1.847 ocorrências, respectivamente. Já gêneros como *Documentary* e *TV Movie* aparecem com menor incidência.




Figure 2. Frequência dos gêneros presentes na base de dados

No caso do pertencimento a coleções ou franquias, 5.014 filmes não pertencem a nenhuma coleção, enquanto 1.904 apresentam vínculo com alguma franquia. Assim, aproximadamente 72,5% da base é composta por filmes sem relação explícita com coleções. Esse atributo é potencialmente informativo porque obras associadas a franquias podem carregar reconhecimento prévio, expectativa de público e padrões específicos de orçamento e arrecadação.

A duração dos filmes apresenta média de aproximadamente 110,9 minutos e desvio padrão de cerca de 21,2 minutos. O menor valor observado foi de 5 minutos e o maior de 254 minutos. Em termos de quartis, 25% dos filmes

possuem até 96 minutos, 50% até 107 minutos e 75% até 121 minutos, o que indica concentração em torno de longas-metragens convencionais. A Figura 3 mostra assimetria à direita, com maior concentração entre 80 e 120 minutos, enquanto o *boxplot* da Figura 4 evidencia a presença de alguns valores atípicos, sobretudo entre filmes mais longos.




Figure 3. Distribuição referente à variável duração




Figure 4. Boxplot referente à variável duração

O orçamento apresenta média de aproximadamente 33,9 milhões de dólares e desvio padrão de 44,2 milhões, o que já sugere alta dispersão. O menor valor observado foi de 1 dólar, o maior chegou a 465,4 milhões, a mediana ficou em 19 milhões e 75% dos filmes possuem orçamento de até 40 milhões. Esse padrão indica que, embora existam produções muito caras, a maior parte da base se concentra em faixas baixas e intermediárias de investimento. A Figura 5 mostra forte assimetria à direita, reforçada pelo *boxplot* da Figura 6, que evidencia diversos *outliers*.




Figure 5. Distribuição referente à variável orçamento

A receita, definida como variável-alvo, apresenta média de aproximadamente 99,0 milhões de dólares e desvio padrão de cerca de 185,9 milhões. O menor valor registrado




Figure 6. Boxplot referente à variável orçamento

foi de 1 dólar, o maior alcançou aproximadamente 2,92 bilhões, a mediana foi de 35,2 milhões e 75% dos filmes arrecadaram até cerca de 104,0 milhões. A Figura 7 mostra uma distribuição fortemente assimétrica à direita, com grande concentração de filmes em faixas mais baixas de arrecadação e uma cauda longa formada por poucos títulos de receita muito elevada. O boxplot da Figura 8 confirma a presença expressiva de *outliers*.

Essa característica da variável-alvo tem papel central na narrativa metodológica do artigo. Ela justifica a construção de partições equilibradas por faixas de arrecadação, motiva a análise posterior dos erros segundo esses mesmos intervalos e explica por que os experimentos adicionais da Seção 5 passam a investigar não apenas o ganho de novos atributos, mas também estratégias específicas para lidar com a heterogeneidade entre regimes de receita. Como análise complementar, esse mesmo comportamento também motivou a avaliação com transformação logarítmica da variável-alvo, apresentada no Apêndice A.




Figure 7. Distribuição referente à variável receita




Figure 8. Boxplot referente à variável receita

4.4 Construção do cenário preliminar mais informado

Uma vez caracterizado o cenário preliminar mais restrito e explicitada a importância da assimetria da receita para o restante do estudo, o passo seguinte foi ampliar, de forma controlada, a quantidade de informação disponível antes da estreia. Para isso, o trabalho avança para um cenário preliminar mais informado por meio de uma nova etapa de coleta na API do TMDB, voltada a metadados mais detalhados sobre as mesmas 6.918 obras já definidas no recorte do estudo. Para a modelagem, foram incorporadas variáveis ligadas ao calendário de estreia, como ano, mês, trimestre, estação do ano e indicadores de lançamento no verão e no fim de ano. Também foram acrescentadas variáveis ligadas à equipe criativa principal, como diretor principal e até três nomes de maior destaque no elenco. Além disso, foram incluídas informações sobre a estrutura produtiva, como produtoras associadas e quantidade de produtoras, bem como medidas relacionadas à escala de créditos de elenco. Em termos metodológicos, esses atributos continuam compatíveis com o recorte pré-lançamento, pois descrevem a janela de estreia e a configuração produtiva do filme, e não sua recepção posterior pelo público. A Tabela 2 resume os atributos adicionais efetivamente incorporados à regressão nessa etapa.

Table 2. Descrição dos atributos adicionais coletados no TMDB para compor o cenário preliminar mais informado

Atributo	Descrição
Ano de estreia (numérico discreto)	Ano da estreia, derivado da data de lançamento.
Mês de estreia (numérico discreto)	Mês da estreia, derivado da data de lançamento.
Trimestre de estreia (categórico)	Trimestre da estreia, representado como Q1, Q2, Q3 ou Q4.
Período sazonal de estreia (categórico)	Estação do ano associada ao lançamento do filme.
Indicador de lançamento no verão (binário)	Indica se o filme estreou no período categorizado como verão.
Indicador de lançamento no fim de ano (binário)	Indica se o filme estreou no período categorizado como fim de ano.
Diretor principal (categórico)	Nome do diretor principal, posteriormente codificado por <i>one-hot</i> para as categorias mais frequentes.
Elenco principal em destaque (categórico multirrótulo)	Até três nomes de maior destaque no elenco, posteriormente codificados por <i>multi-hot</i> .
Produtoras associadas (categórico multirrótulo)	Conjunto de produtoras associadas ao filme, posteriormente codificado por <i>multi-hot</i> .
Quantidade de produtoras (numérico discreto)	Quantidade de produtoras associadas ao filme.
Quantidade de nomes no elenco (numérico discreto)	Quantidade de nomes de elenco retornados pela API para o filme.

Antes de integrar essas variáveis à modelagem, foi realizada uma etapa própria de análise e preparação, análoga ao papel desempenhado pela análise exploratória do conjunto de filmes analisado. Nessa preparação, foram removidas eventuais duplicatas pelo identificador do filme no TMDB, padronizados campos textuais vazios, convertida a data de estreia para tipo temporal e aplicada coerção numérica aos campos derivados da API, como ano e mês

de estreia, número de produtoras, número de nomes no elenco retornado e indicadores binários de sazonalidade. Também foram criadas representações em lista para os campos originalmente armazenados como texto separado por barra vertical, permitindo tratar adequadamente tanto os nomes do elenco principal quanto o conjunto de empresas de produção associadas a cada filme.

Essa inspeção mostrou cobertura praticamente completa dos metadados adicionais sobre o conjunto final de filmes. Todos os 6.918 registros foram recuperados com sucesso. Nos campos centrais usados para derivar ou compor as novas variáveis do modelo, como data de estreia, ano de estreia, diretor principal e produtoras associadas, não foram observados valores ausentes, havendo apenas um caso sem nomes destacados no campo de elenco principal. Ainda assim, a construção do cenário preliminar mais informado não exigiu redução da base nem descarte adicional de filmes, preservando integralmente o conjunto definido na Subseção 4.2.

A análise exploratória desse bloco adicional concentrou-se em três frentes. A primeira foi o calendário de estreia. Observou-se presença de filmes em todos os trimestres, com maior concentração em Q4 (2.019 filmes) e Q3 (1.874), mas ainda com participação expressiva em Q2 (1.579) e Q1 (1.446). Pelo período sazonal de estreia, os lançamentos distribuem-se entre primavera (1.936), inverno (1.750), verão (1.683) e outono (1.549), enquanto 32,4% dos filmes foram marcados como lançamentos de verão e 19,1% como lançamentos de fim de ano. A Figura 9 complementa esse diagnóstico ao mostrar a concentração dos filmes em décadas mais recentes, especialmente a partir dos anos 1990.




Figure 9. Distribuição do ano de estreia no conjunto de metadados adicionais do TMDB

A segunda frente examinou a estrutura produtiva, por meio das contagens de empresas de produção e de nomes creditados no elenco. O número de produtoras associadas variou de 1 a 25, com média de 3,52 por filme, enquanto o número de créditos de elenco variou de 0 a 396, com média de 44,15 e mediana de 38. As Figuras 10 e 11 evidenciam, respectivamente, distribuições assimétricas à direita para essas duas variáveis: a maior parte dos filmes concentra-se em poucas produtoras associadas e em algumas dezenas de nomes no elenco, mas há uma cauda longa de produções com estrutura mais extensa.

A terceira frente investigou a recorrência dos nomes mais frequentes nos campos categóricos. Entre os diretores, destacaram-se Woody Allen (43 filmes), Clint Eastwood




Figure 10. Distribuição da quantidade de produtoras associadas por filme




Figure 11. Distribuição da quantidade de nomes de elenco retornados pela API do TMDB

(36) e Steven Spielberg (33), como mostra a Figura 12. Entre as produtoras associadas, prevaleceram Universal Pictures (479 ocorrências), Warner Bros. Pictures (440) e Paramount Pictures (383), conforme a Figura 13. Já entre os nomes de elenco mais recorrentes, sobressaíram Robert De Niro (66 filmes), Nicolas Cage (64) e Bruce Willis (59), como mostra a Figura 14.




Figure 12. Diretores mais frequentes no conjunto de metadados adicionais do TMDB

Essas análises serviram de base para a codificação do cenário preliminar mais informado. As variáveis temporais e de contagem foram preservadas em formato numérico, os trimestres e períodos de estreia foram transformados em indicadores binários, os diretores mais frequentes foram representados por codificação *one-hot*, e os nomes de elenco




Figure 13. Produtoras mais frequentes considerando o conjunto de empresas de produção associadas a cada filme




Figure 14. Nomes de elenco mais frequentes entre os créditos principais retornados pela API do TMDB

e empresas foram codificados por *multi-hot*, preservando a natureza multirrótulo desses campos. Para controlar a dimensionalidade, foram mantidos os 50 diretores mais frequentes, os 100 nomes mais recorrentes entre os créditos principais do elenco e as 50 produtoras mais frequentes.

Após a integração desses novos atributos à base processada original, o conjunto estendido passou de 73 para 287 colunas, isto é, recebeu 214 novas variáveis sem alterar o número de filmes. Com os dois níveis de informação assim definidos, a etapa seguinte do protocolo estabelece como ambos serão avaliados sob exatamente as mesmas partições, métricas e regras de comparação. Essa comparabilidade é importante porque, como será discutido na Subseção 5.4, é justamente a partir dela que se verifica o ganho do cenário preliminar mais informado e se justifica seu uso como base dos experimentos adicionais de assimetria.

4.5 Protocolo comum de avaliação

Com os dois cenários já construídos, todos os experimentos do estudo passaram a ser avaliados sob um mesmo protocolo de validação. A comparação entre modelos utilizou validação cruzada estratificada com 10 *folds*. Como o problema é de regressão e a receita apresenta distribuição bastante desigual, conforme mostrado na Subseção 4.3, a estratificação foi feita a partir de cinco faixas da variável-alvo definidas por quantis. Esse procedimento foi adotado para distribuir de forma mais equilibrada filmes com diferentes níveis de arrecadação entre as partições. Em cada iteração, um *fold* foi reservado para teste e os demais foram usados para treinamento.

A Tabela 3 apresenta os intervalos de receita utilizados nessa estratificação. Como apenas filmes com receita positiva foram mantidos na base, a primeira faixa se inicia em US\$ 1. Os intervalos são fechados à direita e abertos à esquerda, exceto a primeira faixa, que inclui o menor valor observado. Observa-se que as cinco faixas ficaram praticamente balanceadas, variando entre 1.383 e 1.384 filmes.

Table 3. Faixas de receita utilizadas na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]

As mesmas divisões da validação cruzada foram reutilizadas em todos os experimentos deste recorte: comparação global dos regressores no cenário preliminar mais restrito, análise complementar com transformação logarítmica da variável-alvo, reavaliação dos modelos no cenário preliminar mais informado e experimentos voltados à assimetria da receita, incluindo perdas robustas, regressão por faixa com *oracle*, escolha discreta do especialista e combinação ponderada dos especialistas. Dessa forma, as diferenças observadas entre os resultados refletem as mudanças metodológicas propostas e não variações ocasionais na forma como os dados foram particionados.

Os mesmos cortes de receita também foram preservados na análise posterior dos erros do modelo selecionado, apresentada na Subseção 5.2, e na análise por faixas do Apêndice A.

4.6 Ajuste de hiperparâmetros

Definidas as partições e a forma de comparação entre os cenários, o ajuste de hiperparâmetros foi realizado por *Grid Search*, a partir de conjuntos pré-definidos de configurações para cada regressor. Como a avaliação utilizou validação cruzada com 10 *folds*, a busca foi executada separadamente em cada uma das 10 iterações. Em cada iteração, o *Grid Search* foi conduzido exclusivamente sobre os dados de treinamento, preservando o *fold* de teste para a avaliação final do modelo naquela partição.

A seleção da melhor configuração em cada iteração foi feita com base no menor erro quadrático médio, ou *Mean Squared Error* (MSE), obtido em uma partição interna de validação (*holdout*) extraída do conjunto de treinamento. Esse critério foi adotado porque o MSE penaliza mais fortemente desvios de grande magnitude, o que é particularmente relevante em uma tarefa na qual a variável-alvo apresenta alta variabilidade e presença de valores extremos, conforme observado na Subseção 4.3.

Os conjuntos de hiperparâmetros contemplaram alternativas coerentes com a lógica de funcionamento de cada família de modelos, variando de configurações mais simples a opções de maior flexibilidade preditiva. O mesmo princípio foi mantido nos experimentos complementares: a análise com transformação logarítmica reutilizou a mesma estratégia de ajuste, e os cenários adicionais de robustez e especialização por faixas foram construídos a partir das melhores famílias de modelos obtidas nas comparações globais correspondentes.

4.7 Diagnóstico do melhor modelo em cada cenário

Uma vez definido como os modelos seriam treinados e comparados, a etapa seguinte do protocolo passou a examinar com mais detalhe o comportamento do melhor regressor em cada cenário. Após as comparações globais dos modelos sem transformação da variável-alvo, tanto no cenário preliminar mais restrito quanto no cenário preliminar mais informado, foram realizadas análises adicionais com o objetivo de examinar o comportamento dos erros de predição e a contribuição dos atributos. Em cada um desses cenários, o diagnóstico foi conduzido com base no modelo de melhor desempenho global na respectiva configuração, selecionado a partir da comparação conjunta das métricas de avaliação, considerando menores valores de MSE, RMSE e MAE, além de maior valor de R^2 . No primeiro caso, esse diagnóstico aprofunda a leitura do cenário preliminar mais restrito. No segundo, ele permite verificar se o enriquecimento com novos metadados do TMDb altera não apenas o resultado global, mas também a distribuição dos erros e o conjunto de atributos mais relevantes.

Para a análise dos erros, foram considerados os resíduos, definidos como a diferença entre a receita real e a receita prevista, bem como os erros absolutos obtidos pelo modelo selecionado. A proporção de subestimações foi calculada

como o percentual de casos em que a receita real foi maior que a receita prevista, isto é, quando o resíduo *real* – *predito* foi positivo. De forma complementar, resíduos negativos indicam superestimação. Esses valores foram analisados em relação às faixas de receita dos filmes, permitindo verificar se a dificuldade de predição varia entre obras de baixa, média e alta arrecadação. No encadeamento do artigo, essa etapa funciona como diagnóstico das limitações do melhor regressor global em cada nível de informação pré-lançamento considerado.

Também foi investigada a contribuição dos atributos para as predições do modelo selecionado por meio de *Permutation Feature Importance*, utilizando o MSE como métrica de avaliação. Nessa técnica, mede-se quanto o erro quadrático médio aumenta quando os valores de cada atributo são embaralhados no conjunto de teste. Assim, atributos cuja permutação provoca maior aumento no erro são interpretados como mais relevantes para as predições. Nos experimentos com transformação logarítmica da variável-alvo, apresentados no Apêndice A, os erros por faixa e a importância dos atributos também foram examinados segundo esses mesmos critérios.

4.8 Experimentos adicionais para a assimetria da receita

Os diagnósticos descritos na subseção anterior também serviram para definir a motivação dos experimentos adicionais do artigo. Além da reavaliação global dos modelos com maior nível de informação, foram conduzidos quatro experimentos voltados especificamente à assimetria da receita, todos realizados sobre o cenário preliminar mais informado e sem transformação da variável-alvo. Essa escolha se deve não apenas ao fato de esse cenário representar, dentro do recorte do estudo, o nível mais rico de informação ainda compatível com o período pré-lançamento, mas também ao fato de que, como será mostrado na Subseção 5.4, ele produz o melhor resultado global entre os níveis de informação comparados. Dessa forma, os experimentos adicionais não partem de um cenário arbitrário, mas daquele que oferece a base preditiva mais forte antes da investigação de ganhos metodológicos adicionais. Em todos os experimentos, foram mantidos os mesmos 10 *folds* estratificados, a mesma variável-resposta e as mesmas métricas globais de regressão, de modo que as diferenças observadas pudessem ser atribuídas às estratégias avaliadas, e não a mudanças na amostragem ou no protocolo de avaliação. As cinco faixas de receita descritas na Subseção 4.5 permaneceram como referência comum para esses testes.

Nos três experimentos seguintes, especialista designa um regressor local treinado apenas com exemplos de uma única faixa de receita. Assim, dentro de cada família avaliada, há cinco especialistas, um para cada faixa. Para preservar a comparabilidade com a avaliação global do cenário preliminar mais informado, em cada família de modelos e em cada *fold* foram reaproveitadas as configurações já selecionadas nessa comparação global, e os modelos passaram apenas a ser retreinados em subconjuntos mais homogêneos de receita. Assim, as diferenças observadas podem ser interpretadas como efeito da especialização por

faixa, e não como resultado de uma nova rodada extensa de ajuste de configurações.

4.8.1 Funções de perda robustas

O primeiro experimento investigou se a principal limitação do melhor modelo global decorria sobretudo da sensibilidade da função de perda a grandes erros. Para isolar esse fator, a comparação foi restrita à família vencedora no cenário preliminar mais informado. Como o melhor resultado global nesse cenário foi obtido por *XGBoost Regressor*, como será mostrado na Subseção 5.4, com RMSE de US\$ 111,66 milhões e $R^2 = 0,630$, e esse modelo já opera com objetivo quadrático (*squared error*), foram avaliadas apenas duas variantes robustas dessa mesma família: erro absoluto médio e *Pseudo-Huber*. A lógica dessa escolha foi impedir que mudanças simultâneas de arquitetura e de função de perda mascarassem a interpretação do experimento. Em outras palavras, o objetivo aqui não era buscar um novo vencedor entre famílias de modelos, mas verificar se a simples troca da função de perda, mantendo a mesma classe de regressor, já seria suficiente para enfrentar melhor a cauda superior da distribuição.

4.8.2 Regressão especializada por faixa com oracle

O segundo experimento investigou se parte importante do erro global pode ser explicada pela diferença entre filmes de faixas de arrecadação muito distintas. Para isso, foi avaliada uma regressão especializada por faixa em um cenário controlado, no qual a faixa verdadeira do filme no conjunto de teste era usada apenas como *oracle* analítico. Foram consideradas as três famílias de modelos baseados em árvores que se mostraram mais promissoras no cenário preliminar mais informado, como será mostrado na Subseção 5.4: *Random Forest Regressor*, *Gradient Boosting Regressor* e *XGBoost Regressor*. Em cada *fold* e dentro de cada uma dessas famílias, foram treinados cinco regressores locais, um para cada faixa de receita, sempre usando apenas os exemplos da respectiva faixa no subconjunto de treinamento. Na etapa de teste, a faixa verdadeira determinava qual desses cinco especialistas geraria a predição final. Como essa informação não estaria disponível em uma situação real de uso, esse experimento não é interpretado como uma solução aplicável diretamente, mas como uma referência para estimar quanto a especialização por faixa pode ajudar quando a escolha do especialista é perfeita.

4.8.3 Pipeline híbrido com escolha discreta do especialista

O terceiro experimento procurou transformar a ideia anterior em um pipeline operacional. Para isso, o problema foi decomposto em duas etapas: primeiro, um classificador multiclasse global previa a faixa de receita do filme. Em seguida, essa faixa prevista era usada para selecionar exatamente um entre cinco regressores especialistas da mesma família, cada um treinado apenas com filmes da respectiva faixa. Foram avaliadas três combinações emparelhadas de classificadores e regressores, preservando coerência entre as famílias testadas: *Random Forest Classifier + Random Forest Regressor*, *Gradient Boosting*

Classifier + Gradient Boosting Regressor e *XGBoost Classifier + XGBoost Regressor*. Cada combinação continha, portanto, um classificador global e cinco regressores locais emparelhados. A escolha do melhor classificador em cada *fold* foi feita por *grid search* com *holdout* estratificado interno sobre os dados de treinamento e critério de *macro-F1*, já que o objetivo imediato dessa etapa era manter desempenho equilibrado entre as cinco faixas de receita. Depois disso, o regressor especialista correspondente à faixa prevista produzia a estimativa final da receita. Como a qualidade desse pipeline depende diretamente da etapa classificatória, os resultados passaram a registrar não apenas RMSE, MAE e R^2 , mas também o *macro-F1* da classificação por faixa e diagnósticos complementares da etapa de escolha do especialista.

4.8.4 Pipeline híbrido com combinação ponderada dos especialistas

O quarto experimento manteve a mesma estrutura em dois estágios do caso anterior, isto é, um classificador global emparelhado a cinco regressores especialistas da mesma família, um para cada faixa de receita, porém substituiu a decisão discreta por uma combinação probabilística. Em vez de encaminhar cada filme para apenas um especialista, o classificador passou a fornecer probabilidades para as cinco faixas, e a predição final da receita foi obtida por média ponderada das saídas de todos os especialistas segundo essas probabilidades. O objetivo dessa formulação foi aproveitar a informação contida em previsões classificatórias incertas, sobretudo quando o filme é posicionado próximo à fronteira entre duas faixas adjacentes. Essa estratégia é metodologicamente relevante porque, ao contrário da escolha discreta do especialista, ela não trata todos os erros de classificação como igualmente graves: uma dúvida entre faixas vizinhas pode ainda produzir uma regressão útil se as saídas dos especialistas forem combinadas de maneira coerente. Dessa forma, o experimento com combinação ponderada dos especialistas foi concebido como uma tentativa de recuperar parte do ganho potencial observado no cenário *oracle*, mas sem depender do conhecimento da faixa verdadeira no conjunto de teste.

5 Resultados e Discussão

Os resultados são apresentados seguindo a mesma progressão metodológica estabelecida na Seção 4. Primeiro, discute-se o desempenho global dos regressores no cenário preliminar mais restrito. Em seguida, esse resultado inicial é aprofundado por meio do diagnóstico dos erros por faixa de receita e da importância dos atributos do melhor modelo. Depois, a mesma lógica é repetida no cenário preliminar mais informado, agora com a base enriquecida por novos metadados do TMDb. Só então a seção avança para a investigação de estratégias específicas para lidar com a assimetria da receita. Os apêndices mantêm essa mesma lógica, funcionando como extensões dos resultados principais e não como blocos independentes da narrativa do artigo.

5.1 Resultados globais no cenário preliminar mais restrito

A Tabela 4 apresenta os resultados obtidos nos experimentos sem transformação da variável-alvo, em que a receita foi mantida em sua escala original ao longo dos 10 *folds*, com valores expressos como média e desvio padrão. Nesse primeiro nível de informação, os metadados estruturados utilizados neste trabalho já demonstram capacidade preditiva para a estimação da receita mundial dos filmes, uma vez que os melhores modelos superaram com folga a linha de base simples representada pelo *Dummy Regressor*. Entre os regressores avaliados, o *XGBoost Regressor* apresentou o melhor desempenho global nesse cenário preliminar mais restrito, pois reuniu os resultados mais favoráveis na comparação conjunta das métricas, com menores valores de MSE, RMSE e MAE e maior valor de R^2 . Por esse motivo, esse modelo foi adotado como referência para as análises de erro e de importância dos atributos apresentadas nas subseções seguintes e como ponto de comparação para os resultados obtidos quando o filme passa a ser descrito por um conjunto pré-lançamento mais informado, discutido nas Subseções 5.4 e 5.5.

Mais especificamente, o *XGBoost Regressor* atingiu MSE médio de $1,39 \times 10^{16}$, RMSE médio de US\$ 117,32 milhões, MAE médio de US\$ 58,94 milhões e $R^2 = 0,594$. Esses valores indicam que o modelo foi o mais consistente na comparação global: apresentou os menores erros médios e, ao mesmo tempo, a maior capacidade de explicar a variação da receita em relação a uma estratégia baseada na média. O RMSE, por penalizar mais fortemente grandes desvios, mostra que o *XGBoost Regressor* também foi o modelo mais adequado quando se considera a presença de filmes com arrecadações muito elevadas. Já o MAE indica que, em média, suas previsões se afastaram da receita real em cerca de US\$ 58,94 milhões.

Em seguida, aparecem o *Random Forest Regressor* e o *Gradient Boosting Regressor*, ambos com desempenho bastante próximo ao *XGBoost Regressor*. Esse resultado reforça a adequação de métodos de *ensemble* baseados em árvores para o problema, pois esses modelos conseguem capturar relações não lineares e interações entre atributos como orçamento, coleção, duração, gênero, idioma e receita. A *Linear Regression* também apresentou desempenho competitivo em MSE, RMSE e R^2 , o que sugere que parte da relação entre os atributos e a receita pode ser capturada por uma estrutura mais simples. No entanto, seu MAE mais elevado indica que, em média, seus erros absolutos foram maiores que os dos três melhores modelos. Já o *SVR* apresentou desempenho limitado: embora tenha obtido MAE menor que o *Dummy Regressor*, seu RMSE foi maior e seu R^2 foi negativo, indicando pior desempenho nas métricas mais sensíveis a grandes desvios. Esse comportamento é discutido de forma complementar no Apêndice B.

Como análise complementar, também foram avaliados modelos com transformação logarítmica da variável-alvo, apresentados no Apêndice A. Nessa configuração, a receita foi transformada por meio de $\log(1 + \text{receita})$ durante o treinamento, e as previsões foram posteriormente convertidas de volta para a escala original antes do cálculo das métricas. O papel desse experimento complementar

foi verificar se uma mudança de escala na variável-resposta alteraria a leitura obtida neste primeiro cenário. Os resultados indicaram redução do MAE em alguns modelos, mas não superaram os experimentos sem transformação da variável-alvo em RMSE e R^2 . Dessa forma, considerando o menor RMSE, o maior R^2 e um MAE ainda próximo ao melhor valor observado, o *XGBoost Regressor* treinado sem transformação da variável-alvo foi mantido como o melhor modelo global desse primeiro cenário preliminar.

Com isso, fica definida a referência empírica inicial do estudo: no cenário preliminar mais restrito, os metadados estruturados disponíveis antes da estreia já permitem estimar parcialmente a receita dos filmes, e o *XGBoost Regressor* emerge como a melhor solução global sob o protocolo adotado. A partir daqui, a discussão deixa de se concentrar apenas na comparação entre modelos e passa a examinar as limitações desse primeiro nível de informação.

5.2 Diagnóstico do melhor modelo no cenário preliminar mais restrito

Com o melhor regressor global definido, a etapa seguinte consistiu em entender onde esse desempenho ainda falha. Para isso, foi realizada uma análise dos erros por faixa de receita, retomando os mesmos cortes definidos na etapa de estratificação da validação cruzada, conforme apresentado na Subseção 4.5. Esses cortes dividem a variável-alvo em cinco faixas de arrecadação praticamente balanceadas, permitindo avaliar se o comportamento do modelo varia entre filmes de menor, média e maior receita. Essa leitura é central para a progressão do artigo, pois explicita por que fazia sentido buscar, depois, tanto um cenário pré-lançamento mais informado quanto estratégias específicas para a assimetria da receita.

A Tabela 5 apresenta os resultados por faixa. O padrão mais evidente é o aumento do erro absoluto médio nas faixas superiores. Nas três primeiras faixas, o MAE permanece entre US\$ 26,50 milhões e US\$ 32,40 milhões. Na faixa alta, esse valor sobe para US\$ 41,33 milhões. Na faixa muito alta, porém, ocorre um salto expressivo para US\$ 163,44 milhões. Esse contraste mostra que a maior dificuldade do problema está concentrada justamente na cauda superior da distribuição, composta por filmes de arrecadação mais elevada.

Além da magnitude dos erros, a Tabela 5 também permite observar sua direção. O resíduo médio corresponde à média das diferenças entre a receita real e a receita prevista pelo modelo, isto é, $\text{real} - \text{predito}$. Portanto, valores negativos indicam superestimação, enquanto valores positivos indicam subestimação. Nas faixas muito baixa, baixa e média, predominam superestimações, pois os resíduos médios são negativos e a proporção de subestimações permanece abaixo de 50%. Na faixa alta, observa-se uma região de transição: embora 59,0% dos filmes sejam subestimados, o resíduo médio ainda fica próximo de zero e ligeiramente negativo, indicando maior equilíbrio entre superestimações e subestimações. Já na faixa muito alta, o padrão se inverte com maior clareza, com resíduo médio de US\$ 83,54 milhões e 71,7% de subestimações.

Esse comportamento indica que o modelo apresenta


Table 4. Desempenho dos modelos na predição da receita sem transformação da variável-alvo, ordenados por RMSE. Os valores são apresentados como média $\pm$ desvio padrão ao longo dos 10 *folds*, com o melhor resultado de cada métrica destacado em negrito

Modelo	MSE [10^{16} US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
XGBoost Regressor	1,39 $\pm$ 0,31	117,32 $\pm$ 12,95	58,94 $\pm$ 2,49	0,594 $\pm$ 0,060
Random Forest Regressor	1,44 $\pm$ 0,30	119,31 $\pm$ 12,50	59,53 $\pm$ 2,33	0,579 $\pm$ 0,068
Gradient Boosting Regressor	1,46 $\pm$ 0,32	120,15 $\pm$ 12,87	59,19 $\pm$ 2,67	0,571 $\pm$ 0,086
Linear Regression	1,51 $\pm$ 0,36	122,18 $\pm$ 14,59	63,63 $\pm$ 2,56	0,562 $\pm$ 0,054
Decision Tree Regressor	1,71 $\pm$ 0,32	130,44 $\pm$ 12,01	64,03 $\pm$ 1,94	0,494 $\pm$ 0,097
KNN Regressor	1,73 $\pm$ 0,36	130,87 $\pm$ 13,85	66,96 $\pm$ 3,60	0,497 $\pm$ 0,057
Dummy Regressor	3,45 $\pm$ 0,68	184,99 $\pm$ 18,95	104,67 $\pm$ 3,15	0,000 $\pm$ 0,001
SVR	3,86 $\pm$ 0,71	195,71 $\pm$ 18,74	86,55 $\pm$ 3,11	-0,121 $\pm$ 0,018

Table 5. Métricas do XGBoost Regressor sem transformação da variável-alvo por faixa de receita. Os intervalos seguem os mesmos cortes utilizados na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]	26,50	-26,23	7,4%
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]	32,40	-31,14	11,1%
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]	31,00	-23,51	28,4%
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]	41,33	-2,60	59,0%
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	163,44	83,54	71,7%

difficuldade para representar os extremos da distribuição da receita. Nas faixas de menor arrecadação, as predições tendem a ficar acima dos valores reais, enquanto, na faixa muito alta, tendem a ficar abaixo dos valores observados. Assim, o modelo aproxima melhor os casos mais centrais da base, mas tem menor capacidade de acompanhar filmes com receitas muito baixas ou muito elevadas.

**Figure 15.** Valores reais versus previstos por faixa de receita para o XGBoost Regressor

A Figura 15 reforça visualmente o padrão observado na Tabela 5. A linha tracejada representa o cenário ideal, em que a receita prevista seria igual à receita real. Observa-se que, nas faixas de menor receita, muitos pontos ficam acima dessa linha, confirmando a tendência de superestimação indicada pelos resíduos médios negativos. Nas faixas superiores, especialmente entre os filmes de maior arrecadação, os pontos se tornam mais dispersos e passam a aparecer com maior frequência abaixo da diagonal, o que confirma a maior dificuldade do modelo em acompanhar os casos extremos da distribuição.

Esse diagnóstico mostra que o erro não é homogêneo ao longo das faixas de receita. O modelo tende a superestimar filmes de baixa arrecadação, apresenta comportamento mais equilibrado em faixas intermediárias e passa a subestimar com maior frequência os filmes de receita mais alta. Assim, a principal limitação da abordagem está na dificuldade de representar adequadamente os casos extremos da cauda superior, comportamento que também não foi totalmente resolvido nos experimentos complementares com transformação logarítmica da variável-alvo, apresentados no Apêndice A. Esse diagnóstico passa a orientar os dois movimentos seguintes da seção: primeiro, verificar se um conjunto mais rico de metadados pré-lançamento melhora a predição. Depois, investigar se a heterogeneidade entre faixas de arrecadação pode ser explorada de forma mais direta no próprio desenho dos modelos.

5.3 Atributos mais relevantes no cenário preliminar mais restrito

Se a análise por faixas mostra onde o melhor modelo erra, a etapa seguinte procura esclarecer em que atributos ele mais se apoia para produzir suas predições. Para isso, foi calculada a importância por permutação do XGBoost Regressor. Como descrito na Subseção 4.7, essa técnica avalia quanto o erro do modelo aumenta quando os valores de cada atributo são embaralhados no conjunto de teste. Neste trabalho, a variação foi medida a partir do erro quadrático médio, de modo que maiores aumentos no erro indicam maior relevância do atributo para as predições.

A Figura 16 mostra que a importância dos atributos é bastante concentrada. O orçamento aparece como o atributo mais relevante, com diferença expressiva em relação aos demais. Em seguida, destacam-se o pertencimento a uma coleção e a duração do filme, indicando que características associadas à escala de produção, ao vínculo com franquias e à estrutura da obra tiveram papel importante nas estimativas do modelo. Esses três atributos se sobressaem em relação aos demais, sugerindo que grande parte da capacidade

preditiva do modelo está apoiada em variáveis estruturais diretamente relacionadas à caracterização inicial dos filmes.




Figure 16. Importância média dos atributos por permutação para o *XGBoost Regressor* sem transformação da variável-alvo

Além desses atributos principais, algumas categorias de gênero e idioma original também aparecem com importância positiva, como animação, ficção científica, romance e o idioma inglês. No entanto, essas variáveis apresentam contribuição mais distribuída e menos dominante, o que indica que ajudam a complementar a predição, mas não sustentam o desempenho do modelo no mesmo nível que orçamento, coleção e duração. Também aparecem importâncias médias negativas em alguns atributos. Esses valores não significam que tais características reduzem a receita dos filmes, mas apenas que, nesse experimento, embaralhar esses atributos não aumentou o erro do modelo de forma consistente, sugerindo contribuição fraca, redundante ou instável para as predições.

Tomados em conjunto, os resultados das Subseções 5.1, 5.2 e 5.3 respondem à QP1. Eles mostram que os metadados estruturados disponíveis antes da estreia possuem utilidade preditiva real, mas também revelam um limite claro desse primeiro cenário: a maior dificuldade permanece concentrada na cauda superior da receita. Em termos interpretativos, orçamento, pertencimento a uma coleção e duração figuram como os sinais mais importantes desse nível inicial de descrição do filme, enquanto variáveis categóricas, como gênero e idioma original, atuam de forma mais complementar. Essa leitura ajuda a contextualizar a etapa seguinte do artigo: se, no cenário preliminar mais restrito, a predição já depende fortemente de atributos estruturais, então faz sentido investigar se um aumento controlado de informação pré-lançamento pode melhorar o desempenho sem abandonar o recorte metodológico original.

5.4 Cenário preliminar mais informado: comparação global e diagnóstico

Justamente para verificar se um aumento controlado da informação pré-lançamento poderia melhorar esse quadro, a etapa seguinte incorporou novos metadados do TMDb ligados ao período de estreia, à direção, ao elenco principal e às empresas de produção, mantendo exatamente os mesmos 6.918 filmes e o mesmo protocolo de validação. Com isso, o estudo passa do cenário preliminar mais restrito para um cenário ainda pré-lançamento, mas já mais informado sobre o filme e sua estratégia de lançamento. A Tabela 6 apresenta o desempenho completo dos regressores nesse novo cenário,

permitindo comparação direta com a Tabela 4.

Os resultados mantêm o padrão já observado no cenário preliminar mais restrito, com superioridade das abordagens baseadas em árvores e *boosting*. O *XGBoost Regressor* permaneceu na primeira posição. Em seguida, aparecem novamente o *Gradient Boosting Regressor* e o *Random Forest Regressor*, agora ainda mais próximos do melhor resultado do cenário, todos à frente das alternativas lineares e baseadas em vizinhança. Isso indica que o enriquecimento da informação pré-lançamento não mudou o perfil das famílias mais competitivas, mas elevou o desempenho global do conjunto mais promissor de regressores.

A comparação direta entre as Tabelas 4 e 6 mostra que o enriquecimento com novos metadados do TMDb reduziu o RMSE do melhor modelo em 4,82% e o MAE em 6,42%, além de elevar o R^2 em 0,036 ponto. Esses resultados indicam que informações adicionais ainda disponíveis antes do lançamento, como janela de estreia, direção, elenco principal e estrutura de produção, ajudam a refinar a estimativa da receita sem exigir alteração no conjunto de filmes nem no protocolo de avaliação. Em outras palavras, passar de um cenário preliminar mais restrito para um cenário preliminar mais informado já produz ganho mensurável de predição.

Esse ganho também é coerente com a natureza dos novos atributos incorporados. Variáveis temporais de lançamento podem captar diferenças de calendário associadas à disputa por público e à sazonalidade do consumo. Já informações sobre direção, elenco principal e empresas de produção introduzem no modelo sinais indiretos sobre escala industrial, histórico de participação em projetos de maior visibilidade e inserção do filme em circuitos produtivos mais consolidados. Embora nenhuma dessas variáveis represente diretamente a resposta do público, elas enriquecem a caracterização pré-lançamento da obra e ajudam a reduzir parte da incerteza presente no primeiro cenário analisado.

Vale notar, ainda, que a incorporação desses novos atributos não alterou a família do melhor regressor global entre os modelos originalmente comparados, mas aumentou sua capacidade preditiva. Em termos narrativos, isso mostra que a melhoria mais imediata da metodologia não veio da substituição do tipo de modelo, e sim do aumento da qualidade e da granularidade das informações disponíveis sobre o filme ainda antes da estreia. Assim, a passagem para o cenário preliminar mais informado não interrompe o raciocínio construído até aqui. Ela responde diretamente à limitação observada no primeiro cenário ao ampliar, de forma controlada, o conjunto de sinais estruturados acessíveis ao modelo.

5.4.1 Erros por faixa no cenário preliminar mais informado

Como o melhor regressor global permaneceu sendo o *XGBoost Regressor*, o passo seguinte foi verificar se o enriquecimento com metadados adicionais também alterava a distribuição dos erros ao longo das faixas de receita. Para isso, repetiu-se exatamente o mesmo diagnóstico aplicado ao cenário preliminar mais restrito, preservando os mesmos cinco cortes de arrecadação.

Table 6. Desempenho dos modelos no cenário preliminar mais informado, sem transformação da variável-alvo, ordenados por RMSE. Os valores são apresentados como média $\pm$ desvio padrão ao longo dos 10 *folds*, com o melhor resultado de cada métrica destacado em negrito

Modelo	MSE [10^{16} US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
XGBoost Regressor	1,27 $\pm$ 0,36	111,66 $\pm$ 15,00	55,16 $\pm$ 2,52	0,630 $\pm$ 0,078
Gradient Boosting Regressor	1,29 $\pm$ 0,36	112,71 $\pm$ 15,06	55,70 $\pm$ 2,31	0,623 $\pm$ 0,083
Random Forest Regressor	1,31 $\pm$ 0,35	113,78 $\pm$ 14,90	55,22 $\pm$ 2,32	0,615 $\pm$ 0,083
Linear Regression	1,49 $\pm$ 0,37	121,19 $\pm$ 15,06	63,86 $\pm$ 2,14	0,569 $\pm$ 0,060
KNN Regressor	1,85 $\pm$ 0,35	135,47 $\pm$ 13,32	66,93 $\pm$ 3,17	0,460 $\pm$ 0,056
Decision Tree Regressor	1,92 $\pm$ 0,41	137,73 $\pm$ 14,96	64,81 $\pm$ 2,61	0,409 $\pm$ 0,258
Dummy Regressor	3,45 $\pm$ 0,68	184,99 $\pm$ 18,95	104,67 $\pm$ 3,15	-0,000 $\pm$ 0,001
SVR	3,86 $\pm$ 0,71	195,71 $\pm$ 18,74	86,55 $\pm$ 3,11	-0,121 $\pm$ 0,018


Table 7. Métricas do XGBoost Regressor no cenário preliminar mais informado, sem transformação da variável-alvo, por faixa de receita. Os intervalos seguem os mesmos cortes utilizados na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]	22,42	-22,00	10,6%
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]	28,53	-26,71	12,7%
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]	30,25	-21,83	31,5%
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]	41,33	-2,84	58,3%
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	153,22	71,02	70,5%

A Tabela 7 mostra que o padrão geral do problema permanece: o erro cresce à medida que se avança para as faixas superiores, e a maior dificuldade continua concentrada na cauda de arrecadação mais alta. Ainda assim, o enriquecimento com metadados do TMDb trouxe ganhos relevantes em boa parte da distribuição. Em relação ao cenário preliminar mais restrito, o MAE caiu de US\$ 32,40 milhões para US\$ 28,53 milhões na faixa baixa e de US\$ 163,44 milhões para US\$ 153,22 milhões na faixa muito alta. O RMSE também recuou nas faixas baixa, média, alta e muito alta, com destaque para a redução de aproximadamente US\$ 11,12 milhões na cauda superior. A única exceção foi a faixa muito baixa, na qual o MAE melhorou, mas o RMSE subiu levemente de US\$ 39,45 milhões para US\$ 40,67 milhões.

A direção dos erros também se manteve semelhante, porém um pouco menos acentuada nas faixas superiores. Nas três primeiras faixas, os resíduos médios continuam negativos, indicando tendência de superestimação. Na faixa alta, o resíduo médio permanece próximo de zero, o que caracteriza uma região de transição entre superestimação e subestimação. Já na faixa muito alta, o resíduo médio continua positivo, mas cai de US\$ 83,54 milhões para US\$ 71,02 milhões, enquanto a proporção de subestimações recua de 71,7% para 70,5%. Portanto, os novos atributos não eliminam a dificuldade de acompanhar os maiores sucessos de bilheteria, mas reduzem parcialmente esse desvio justamente na região mais crítica do problema.

A Figura 17 reforça essa leitura. A diagonal tracejada continua representando o comportamento ideal, e observa-se que os pontos das faixas de menor receita permanecem majoritariamente acima dessa linha, refletindo a superestimação já indicada pelos resíduos médios negativos. Nas faixas superiores, os pontos ainda se tornam mais dispersos e passam a aparecer com frequência abaixo da diagonal, sobretudo entre os filmes de muito alta arrecadação. Em comparação com a figura correspondente do cenário preliminar mais restrito, percebe-se uma

**Figure 17.** Valores reais versus previstos por faixa de receita para o XGBoost Regressor no cenário preliminar mais informado

aproximação ligeiramente melhor da diagonal em parte das faixas intermediárias e altas, mas sem desaparecimento da cauda de grandes subestimações.

5.4.2 Atributos mais relevantes no cenário preliminar mais informado

Depois de verificar como os erros se redistribuem nas faixas de receita, a análise volta-se para a base do comportamento preditivo do modelo nesse segundo cenário. A Figura 18 apresenta a importância por permutação do melhor modelo global nessa configuração mais informada. O orçamento permanece, com ampla margem, como a variável mais influente. Em seguida, continuam aparecendo com destaque o pertencimento a uma coleção e a duração do filme, o que mostra que os principais sinais estruturais do cenário preliminar mais restrito continuam sustentando a maior parte da capacidade preditiva do modelo.

A diferença, porém, é que agora passam a aparecer entre os atributos mais relevantes variáveis que não existiam no primeiro cenário, especialmente ligadas ao calendário




Figure 18. Importância média dos atributos por permutação para o *XGBoost Regressor* no cenário preliminar mais informado

de estreia e à estrutura produtiva do filme. Entre elas destacam-se o ano de estreia, a quantidade de produtoras associadas, a quantidade de nomes de elenco retornados pela API e o mês de estreia. Também surgem com importância positiva indicadores associados a nomes recorrentes de elenco, direção e empresas de produção, como Sigourney Weaver, Robert Downey Jr., Steven Spielberg e Universal Pictures. Esses sinais não devem ser interpretados como efeitos causais isolados, mas como indícios do contexto de lançamento e da escala de produção em que o filme se insere. Sua presença entre as variáveis mais relevantes sugere que o cenário preliminar mais informado não só melhora o desempenho global, como também amplia o tipo de informação pré-lançamento que o modelo consegue aproveitar.

Esse segundo bloco responde à QP2. A incorporação de metadados adicionais do TMDb em um estágio pré-lançamento mais informado produz ganho mensurável em relação ao cenário preliminar mais restrito, sem alterar o conjunto de filmes nem o protocolo de avaliação. Além disso, esse ganho não se limita ao agregado global: ele também aparece na análise por faixas, sobretudo nas faixas baixa e muito alta, e vem acompanhado de uma redistribuição parcial da importância dos atributos, que passa a incorporar sinais de calendário e estrutura produtiva. Ao mesmo tempo, o diagnóstico mostra que a heterogeneidade entre faixas de arrecadação permanece como limitação relevante, o que justifica a etapa seguinte de experimentos metodológicos específicos.

5.5 Estratégias adicionais para a assimetria da receita no cenário preliminar mais informado

Os resultados seguintes partem justamente dos dois diagnósticos realizados até aqui. A análise por faixas do cenário preliminar mais restrito identificou a cauda superior como principal foco de erro, e a repetição dessa leitura no cenário preliminar mais informado mostrou que, embora o enriquecimento com metadados do TMDb reduza parte desses desvios, a heterogeneidade residual entre faixas de arrecadação permanece. Como mostrado na Subseção 5.4, esse segundo cenário também fornece a melhor base preditiva entre os níveis de informação pré-lançamento comparados, razão pela qual os experimentos adicionais passam a ser conduzidos sobre ele. Assim, os testes seguintes investigam se esse comportamento residual

pode ser explorado metodologicamente de forma mais direta sem abrir mão da melhor base preditiva obtida até então. Mais especificamente, cada estratégia testa uma hipótese distinta sobre a origem dessa limitação. As perdas robustas verificam se o problema decorre principalmente da penalização de grandes erros. O cenário *oracle* estima o quanto se poderia ganhar se a faixa de arrecadação fosse conhecida com perfeição. O pipeline híbrido com escolha discreta de um único especialista examina se essa ideia pode ser operacionalizada de forma prática. Já a combinação ponderada dos especialistas investiga se a incerteza classificatória pode ser aproveitada em vez de descartada. A Tabela 8 sintetiza os melhores resultados de cada uma dessas possibilidades tomando como referência o melhor regressor global do cenário preliminar mais informado.

A partir dessa visão agregada, as subseções seguintes detalham separadamente as variantes de perdas robustas, as famílias avaliadas no cenário *oracle* e o diagnóstico classificatório compartilhado pelos dois pipelines híbridos.

5.5.1 Perdas robustas

A Tabela 9 detalha as duas variantes robustas avaliadas dentro da família vencedora do cenário preliminar mais informado e deve ser lida em comparação com o *XGBoost Regressor* padrão discutido na Subseção 5.4, cujo objetivo já é *squared error*. Os testes com funções de perda robustas não produziram ganho efetivo sobre esse modelo de referência. O objetivo baseado em erro absoluto reduziu o MAE para US\$ 51,58 milhões, mas ao custo de piorar o RMSE para US\$ 113,82 milhões e reduzir o R^2 para 0,620. Em termos interpretativos, isso significa que a nova perda ajudou a aproximar parte dos casos típicos da base, mas não melhorou o comportamento global justamente nas métricas mais sensíveis aos grandes desvios que motivam este bloco do artigo. O resultado com *Pseudo-Huber*, por sua vez, foi claramente inferior em todas as métricas principais, indicando que, neste conjunto de dados, a simples troca da função de perda não foi suficiente para tornar a mesma família de modelos mais adequada à cauda superior da distribuição. Em conjunto, essas evidências sugerem que a principal limitação do problema não está apenas na forma como o erro extremo é penalizado, mas também na heterogeneidade entre diferentes regimes de arrecadação. Se o problema não se resolve por uma simples mudança de função de perda, o passo seguinte é perguntar quanto se poderia ganhar ao separar explicitamente filmes pertencentes a regimes de receita distintos.

5.5.2 Especialistas por faixa com oracle

A Tabela 10 responde justamente a essa pergunta em um cenário controlado. Quando a faixa verdadeira do filme é conhecida no conjunto de teste e usada para selecionar um regressor especializado, o melhor resultado passa para o *Gradient Boosting Regressor*, com RMSE de US\$ 96,85 milhões, MAE de US\$ 33,36 milhões e $R^2 = 0,720$. Em relação ao melhor regressor global do cenário preliminar mais informado, isso corresponde a reduções de 13,26% em RMSE e 39,52% em MAE, magnitude muito superior àquela obtida apenas com a troca da função de perda. Além disso, a própria tabela mostra que as três famílias

Table 8. Comparação entre as estratégias adicionais voltadas à assimetria da receita, tomando como referência o melhor resultado global no cenário preliminar mais informado

Estratégia	Melhor configuração	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
Cenário preliminar mais informado	<i>XGBoost Regressor</i>	111,66	55,16	0,630
Melhor perda robusta	<i>XGBoost (MAE)</i>	113,82	51,58	0,620
Oracle por faixa	<i>Gradient Boosting Regressor</i>	96,85	33,36	0,720
Escolha discreta	<i>Gradient Boosting Classifier + Gradient Boosting Regressor</i>	117,84	58,89	0,586
Combinação ponderada	<i>Gradient Boosting Classifier + Gradient Boosting Regressor</i>	108,62	54,02	0,650

Table 9. Detalhamento das configurações avaliadas no experimento de perdas robustas, no cenário preliminar mais informado

Configuração	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
<i>XGBoost (MAE)</i>	113,82	51,58	0,620
<i>XGBoost (Pseudo-Huber)</i>	209,86	98,93	-0,292

avaliadas no cenário *oracle* produziram resultados bastante próximos entre si e todas superaram com folga o melhor regressor global. Essa proximidade sugere que, uma vez conhecida a faixa correta, a especialização por regimes mais homogêneos pesa mais do que a escolha fina entre as famílias de *ensemble* avaliadas. Portanto, há ganho estrutural real em modelar a receita por faixas, mas esse cenário depende de uma informação que não estaria disponível em uso prático, funcionando apenas como teto otimista para as abordagens subsequentes. Justamente por isso, a questão seguinte deixa de ser se especialistas ajudam e passa a ser como acioná-los quando a faixa verdadeira não está disponível no uso prático.

Table 10. Detalhamento das famílias avaliadas no cenário *oracle* por faixa, no cenário preliminar mais informado

Configuração	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
<i>Random Forest Regressor</i>	98,19	32,95	0,707
<i>XGBoost Regressor</i>	97,44	33,56	0,716
<i>Gradient Boosting Regressor</i>	96,85	33,36	0,720

5.5.3 Pipeline híbrido com escolha discreta do especialista

O primeiro teste operacional dessa ideia é o pipeline híbrido com escolha discreta do especialista, no qual a faixa é prevista por um classificador e, em seguida, apenas um especialista é acionado. O melhor pipeline nesse caso foi *Gradient Boosting Classifier + Gradient Boosting Regressor*, mas o desempenho final foi inferior ao melhor regressor global do cenário preliminar mais informado, com RMSE de US\$ 117,84 milhões, MAE de US\$ 58,89 milhões e $R^2 = 0,586$. Esse resultado é particularmente relevante porque mostra que a boa ideia do cenário *oracle* não se transfere automaticamente para um pipeline operacional. A Tabela 11 ajuda a interpretar esse fracasso. O *macro-F1* dessa etapa de classificação ficou em aproximadamente 47,0%, isto é, a separação exata entre as cinco faixas ainda é modesta. Ao mesmo tempo, 84,1% dos filmes foram atribuídos à faixa correta ou a uma faixa adjacente. Em outras palavras, o classificador frequentemente reconhece a vizinhança correta do filme, mas esse nível de acerto ainda não basta quando

a decisão final depende de escolher apenas um especialista. Nesse regime discreto, um erro de uma faixa para a vizinha já pode ser suficiente para deslocar a predição para um modelo inadequado ao caso, deteriorando o resultado global. Assim, a decomposição classificação-regressão não fracassa por falta total de informação classificatória, mas porque escolher apenas um especialista exige um grau de precisão que o classificador ainda não consegue sustentar de maneira estável. Esse resultado, porém, não encerra a ideia de especialistas por faixa: ele sugere, na verdade, que a informação classificatória disponível talvez ainda seja útil se for incorporada de maneira menos rígida.

5.5.4 Pipeline híbrido com combinação ponderada dos especialistas

É exatamente essa hipótese que orienta o experimento com combinação ponderada dos especialistas, no qual os mesmos classificadores e especialistas do cenário anterior são mantidos, mas a previsão final passa a ser uma combinação ponderada das saídas dos especialistas pelas probabilidades previstas pelo classificador. A Tabela 11 mostra que o diagnóstico classificatório permanece o mesmo nos dois cenários híbridos: o *macro-F1*, a proporção de acertos exatos ou vizinhos e a confiança média não mudam. Essa igualdade já era esperada, porque os dois cenários compartilham exatamente o mesmo classificador e diferem apenas na forma como a sua saída é usada para acionar os especialistas. Ainda assim, o melhor pipeline nessa formulação, novamente *Gradient Boosting Classifier + Gradient Boosting Regressor*, melhora substancialmente a regressão: o RMSE cai para US\$ 108,62 milhões, o MAE para US\$ 54,02 milhões e o R^2 sobe para 0,650. Em relação ao híbrido com escolha discreta do especialista, isso representa reduções de 7,83% em RMSE e 8,27% em MAE, sem qualquer mudança na etapa classificatória. Esse contraste é central para a interpretação do experimento, porque mostra que o ganho não veio de um classificador melhor, e sim de uma forma mais adequada de usar exatamente a mesma informação classificatória. Em vez de tratar a incerteza entre faixas como erro puro, essa combinação ponderada a transforma em ponderação entre especialistas vizinhos, reduzindo a penalidade de escolhas discretas incorretas do especialista. Em relação ao melhor regressor global do cenário preliminar mais informado, essa estratégia ainda obteve melhora adicional de 2,72% em RMSE, 2,06% em MAE e 0,020 em R^2 , o que a torna o melhor resultado prático do estudo dentro do recorte estritamente pré-lançamento.

A análise por faixa mostrou que esse ganho da

Table 11. Comparação entre os melhores pipelines híbridos com escolha discreta e combinação ponderada dos especialistas, ambos no cenário preliminar mais informado

Estratégia	RMSE [US\$ mi]	MAE [US\$ mi]	R^2	Macro-F1 [%]	Faixa correta ou vizinha [%]	Confiança média [%]
Escolha discreta	117,84	58,89	0,586	47,0	84,1	49,1
Combinação ponderada	108,62	54,02	0,650	47,0	84,1	49,1

combinação ponderada dos especialistas se concentrou principalmente nas regiões que já haviam sido identificadas como mais problemáticas: comparado ao melhor regressor global do cenário preliminar mais informado, o novo pipeline reduziu o RMSE em 5,24% na faixa média, 5,13% na faixa alta e 2,49% na faixa muito alta, além de reduzir o MAE em 7,58%, 4,08% e 1,40% nessas mesmas faixas. Nas duas faixas mais baixas, por outro lado, o comportamento ficou próximo ao do regressor global, sem ganhos consistentes em MAE. Isso é coerente com toda a narrativa construída até aqui: a principal dificuldade não estava concentrada nos casos mais modestos da distribuição, mas justamente nas regiões em que a fronteira entre faixas e a heterogeneidade de arrecadação se tornam mais problemáticas. Assim, a combinação ponderada dos especialistas não elimina completamente a dificuldade de modelar a cauda superior da distribuição, mas consegue atacar precisamente a parte do problema em que o melhor regressor global ainda mostrava maior fragilidade, recuperando parte relevante do ganho potencial apontado pelo cenário *oracle*.

Em conjunto, esses resultados mostram uma progressão metodológica mais informativa do que uma simples comparação entre técnicas isoladas. Ampliar o conjunto de informações pré-lançamento melhora o melhor resultado inicial, mas não elimina a heterogeneidade entre faixas de arrecadação. A etapa de perdas robustas mostra que o problema não se resolve apenas tornando a função de perda menos sensível a desvios extremos. O cenário *oracle*, por sua vez, revela que existe potencial real em especializar a regressão por regimes mais homogêneos. O fracasso da escolha discreta de um único especialista indica que esse potencial não pode ser convertido diretamente por uma decisão classificatória única e rígida. Já a combinação ponderada dos especialistas mostra que a informação probabilística sobre a faixa do filme, mesmo imperfeita, pode ser incorporada de modo produtivo à regressão. Assim, a QP3 é respondida de forma direta: a heterogeneidade entre faixas de receita não é apenas uma fonte de erro, mas uma estrutura do problema que pode ser explorada para melhorar a predição. Nesse sentido, os experimentos adicionais não formam um bloco paralelo à análise principal, e sim um desdobramento direto do que foi observado nos cenários anteriores, especialmente da persistência dos maiores desvios nas faixas superiores mesmo após o enriquecimento da informação pré-lançamento.

6 Conclusão

Este trabalho investigou a predição da receita mundial de filmes a partir de metadados estruturados disponíveis antes da estreia, extraídos da API pública do TMDb. Em vez de limitar a análise a uma única configuração fixa de atributos, o estudo foi organizado como uma progressão de informação

pré-lançamento: primeiro, um cenário preliminar mais restrito, baseado em características estruturais imediatas da obra. Depois, um cenário preliminar mais informado, enriquecido com variáveis ligadas ao calendário de estreia, à direção, ao elenco principal e às empresas de produção. Sobre esse segundo nível de informação, também foram avaliadas estratégias específicas para lidar com a assimetria da variável-alvo e com a heterogeneidade entre faixas de arrecadação.

No cenário preliminar mais restrito, os resultados mostraram que os metadados estruturados possuem capacidade preditiva real, ainda que parcial. O *XGBoost Regressor* apresentou o melhor desempenho global sem transformação da variável-alvo, superando os demais modelos em MSE, RMSE, MAE e R^2 . A análise por faixa indicou que esse desempenho não é homogêneo ao longo da distribuição da receita: o modelo tende a superestimar filmes de menor arrecadação e a subestimar, com maior frequência, filmes de muito alta receita. A análise de importância dos atributos mostrou forte concentração em orçamento, pertencimento a uma coleção e duração, sugerindo que grande parte da capacidade preditiva inicial do modelo está apoiada em sinais estruturais ligados à escala de produção, ao vínculo com franquias e à configuração básica da obra.

Como análises complementares, os experimentos com transformação logarítmica da variável-alvo reduziram o MAE em alguns casos, mas não alteraram a conclusão principal do estudo, já que os melhores valores de RMSE e R^2 permaneceram associados aos experimentos conduzidos na escala original da receita. Além disso, a investigação específica do SVR indicou que seu desempenho inferior nas métricas mais sensíveis a grandes desvios esteve associado à forte assimetria da receita e à produção de predições excessivamente concentradas em valores centrais da distribuição.

Ao incorporar metadados adicionais do TMDb, observou-se que há espaço para melhorar a predição ainda dentro de um contexto estritamente pré-lançamento. No cenário preliminar mais informado, o melhor regressor global continuou sendo o *XGBoost Regressor*, mas com redução de 4,82% no RMSE e de 6,42% no MAE em relação ao melhor resultado inicial. O diagnóstico desse segundo cenário indicou que o padrão de erro por faixa permaneceu semelhante, embora com reduções relevantes em boa parte da distribuição, inclusive na faixa de muito alta arrecadação. Na leitura dos atributos, passou a aparecer, além de orçamento, coleção e duração, um conjunto de sinais associados ao calendário de estreia e à estrutura produtiva do filme. Com isso, o ganho do cenário mais informado não se limitou ao resultado agregado: ele também apareceu na análise por faixas e na redistribuição parcial da importância dos atributos.

Os experimentos adicionais voltados à assimetria da receita permitiram refinar ainda mais essa leitura. Funções de perda robustas não superaram o *XGBoost* padrão, o que indica que a dificuldade central não está apenas na sensibilidade da função de perda a erros extremos. Em contrapartida, o cenário *oracle* por faixa confirmou que a especialização por regimes de arrecadação possui grande potencial quando a escolha do especialista é perfeita. O pipeline híbrido com escolha discreta do especialista não conseguiu transformar esse potencial em ganho prático, justamente porque a etapa classificatória ainda se mostrou frágil para sustentar uma decisão discreta confiável. Já a combinação ponderada entre especialistas por faixa produziu o melhor resultado prático do estudo, com RMSE de US\$ 108,62 milhões, MAE de US\$ 54,02 milhões e $R^2 = 0,650$, ao aproveitar a informação probabilística do classificador em vez de tratá-la como uma escolha única e irreversível.

Em síntese, os resultados mostram que a dificuldade principal do problema não está apenas na presença de valores extremos, mas também na heterogeneidade entre diferentes faixas de arrecadação. Quando essa heterogeneidade é ignorada, os maiores erros permanecem concentrados na cauda superior da receita. Quando ela é explorada com um conjunto mais rico de informações pré-lançamento e com mecanismos de modelagem capazes de lidar melhor com a incerteza entre faixas vizinhas, o desempenho melhora de forma mensurável. Como continuidade natural deste estudo, um próximo passo é aperfeiçoar a etapa que decide como cada filme deve ser encaminhado entre os especialistas por faixa. Isso pode ser feito, por exemplo, com classificadores que considerem explicitamente a ordem natural entre as faixas de arrecadação, com estratégias para tornar as probabilidades previstas mais confiáveis, com mecanismos que permitam recorrer ao melhor regressor global quando a incerteza for elevada e com novas formas de definir as próprias faixas de receita. Além disso, seguem promissoras outras fontes de informação disponíveis antes da estreia, desde que sua incorporação preserve o cuidado metodológico de evitar vazamento temporal na predição da receita.

Declarações complementares

Authors' Contributions

Sob orientação do docente responsável pela disciplina de Aprendizado de Máquina, o autor foi responsável pela concepção do estudo, preparação dos dados, definição da metodologia, implementação dos experimentos, análise dos resultados e escrita, revisão e edição do manuscrito.

Competing interests

O autor declara que não possui conflitos de interesse.

Availability of data and materials

Os conjuntos de dados analisados e os códigos-fonte desenvolvidos durante o estudo atual estão disponíveis em: github.com/gabrielprenassi/UFESJ_Aprendizado_Maquina_TP1.

References

Abidi, S. M. R., Xu, Y., Ni, J., Wang, X., and Zhang, W. (2020). Popularity prediction of movies: from statistical

- modeling to machine learning techniques. *Multimedia Tools and Applications*, 79(47):35583–35617.
- Ahmad, I. S., Bakar, A. A., and Yaakub, M. R. (2020a). Movie revenue prediction based on purchase intention mining using youtube trailer reviews. *Information Processing & Management*, 57(5):102278.
- Ahmad, I. S., Bakar, A. A., Yaakub, M. R., and Muhammad, S. H. (2020b). A survey on machine learning techniques in movie revenue prediction. *SN Computer Science*, 1(4):235.
- Ghiassi, M., Lio, D., and Moon, B. (2015). Pre-production forecasting of movie revenues with a dynamic artificial neural network. *Expert Systems with Applications*, 42(6):3176–3193.
- Gupta, V., Jain, N., Garg, H., Jhunthra, S., Mohan, S., Omar, A. H., and Ahmadian, A. (2023). Predicting attributes based movie success through ensemble machine learning. *Multimedia Tools and Applications*, 82(7):9597–9626.
- James, G., Witten, D., Hastie, T., Tibshirani, R., and Taylor, J. (2023). Statistical learning. In *An introduction to statistical learning: With applications in Python*, pages 15–67. Springer.
- Kim, T., Hong, J., and Kang, P. (2015). Box office forecasting using machine learning algorithms based on sns data. *International Journal of Forecasting*, 31(2):364–390.
- Lash, M. T. and Zhao, K. (2016). Early predictions of movie success: The who, what, and when of profitability. *Journal of Management Information Systems*, 33(3):874–903.
- Madongo, C. T. and Zhongjun, T. (2023). A movie box office revenue prediction model based on deep multimodal features. *Multimedia Tools and Applications*, 82(21):31981–32009.
- Mammadov, S., Abdulrashid, I., Khalafalla, M., and Delen, D. (2025). Identifying factors influencing box-office success of motion pictures with xai. *Journal of Computer Information Systems*, pages 1–17.
- Murphy, K. P. (2022). *Probabilistic machine learning: an introduction*. MIT press.
- Quader, N., Gani, M. O., Chaki, D., and Ali, M. H. (2017). A machine learning approach to predict movie box-office success. In *2017 20th International Conference of Computer and Information Technology (ICCIT)*, pages 1–7. IEEE.
- Sharda, R. and Delen, D. (2006). Predicting box-office success of motion pictures with neural networks. *Expert Systems with Applications*, 30(2):243–254.
- Udandara, V. and Gupta, P. (2024). Movie revenue prediction using machine learning models. *arXiv preprint arXiv:2405.11651*.
- Zhou, Y., Zhang, L., and Yi, Z. (2019). Predicting movie box-office revenues using deep neural networks. *Neural Computing and Applications*, 31(6):1855–1865.

A Experimentos complementares com transformação logarítmica da variável-alvo

Este apêndice complementa a leitura da Seção 5 ao documentar a alternativa baseada em transformação logarítmica da variável-alvo. Diferentemente das extensões com novos metadados do TMDb e dos experimentos voltados à assimetria por faixas, este bloco não inaugura uma nova frente metodológica do artigo. Seu papel é verificar se uma mudança de escala na variável-resposta alteraria as conclusões obtidas no cenário preliminar mais restrito. Por isso, a apresentação segue a mesma ordem da seção principal: comparação global entre regressores, diagnóstico por faixa de receita e importância dos atributos do modelo selecionado nessa configuração.

Como discutido na Subseção 4.3, a motivação para esse teste veio da forte assimetria da receita, marcada pela concentração de muitos filmes em faixas mais baixas de arrecadação e pela presença de poucos títulos com receitas muito elevadas. Nos experimentos, a receita foi transformada por meio de $\log(1 + \text{receita})$ durante o treinamento, e as predições foram posteriormente reconvertidas para a escala original antes do cálculo das métricas finais. Dessa forma, os resultados permaneceram diretamente comparáveis àqueles apresentados na Subseção 5.1.

A.1 Resultados globais com transformação logarítmica no cenário preliminar mais restrito

A Tabela 12 apresenta o desempenho médio dos modelos treinados com transformação logarítmica da variável-alvo. Nessa avaliação, o *Random Forest Regressor* obteve o melhor desempenho em MSE, RMSE e R^2 , com MSE médio de $1,52 \times 10^{16}$ US\$, RMSE médio de US\$ 122,50 milhões e $R^2 = 0,560$. O menor MAE, por pequena diferença, foi obtido pelo *XGBoost Regressor*, com US\$ 55,62 milhões. Assim, dentro desta configuração específica, o *Random Forest Regressor* foi adotado como referência para as análises por faixa e de importância dos atributos apresentadas nas subseções seguintes.

Em comparação com os experimentos sem transformação da variável-alvo, a transformação logarítmica trouxe ganhos localizados, mas não alterou a conclusão geral do estudo. Embora tenha reduzido o MAE em alguns modelos, indicando menor erro absoluto médio, ela não levou aos melhores resultados em RMSE e R^2 . Esses valores permaneceram associados ao *XGBoost Regressor* treinado diretamente sobre a receita em sua escala original, com RMSE de US\$ 117,32 milhões e $R^2 = 0,594$. Assim, o melhor desempenho global do estudo permaneceu associado ao *XGBoost Regressor* sem transformação da variável-alvo, e a análise com $\log(1 + \text{receita})$ deve ser lida como uma verificação complementar, e não como substituição da trilha principal de resultados.

Esse comportamento pode ser explicado pelo efeito da transformação logarítmica sobre a cauda superior da distribuição. Ao comprimir valores muito elevados durante o treinamento, a transformação reduz a influência dos filmes de arrecadação extrema e favorece a aproximação de casos

mais frequentes da base. No entanto, como as métricas finais foram calculadas após a reconversão das predições para dólares, erros em filmes de alta arrecadação continuaram tendo grande impacto sobre medidas sensíveis a grandes desvios, como RMSE e R^2 . Dessa forma, a transformação ajudou em parte da distribuição, mas não resolveu a principal dificuldade identificada na Seção 5.

A Tabela 12 também mostra que a transformação logarítmica não afetou todos os modelos da mesma forma. A *Linear Regression*, que sem transformação havia obtido desempenho competitivo, apresentou deterioração acentuada com a variável-alvo transformada, alcançando RMSE médio de US\$ 4,28 bilhões e R^2 médio de $-1186,466$, além de desvios padrão muito elevados entre os *folds*. Esse contraste sugere que a relação entre os preditores e a receita não foi bem representada por uma estrutura linear no espaço logarítmico, levando a predições muito distantes dos valores reais após a reconversão para dólares.

A.2 Diagnóstico por faixa de receita com transformação logarítmica

Assim como na análise principal, a avaliação por faixa de receita utilizou os mesmos cortes definidos na estratificação dos *folds*. Essa escolha preserva a comparabilidade direta com a Subseção 5.2 e permite observar se os efeitos da transformação logarítmica se distribuem de forma homogênea ao longo da receita ou se ficam concentrados em determinadas regiões da variável-alvo.

Os resultados da Tabela 13 indicam que a transformação logarítmica foi mais favorável nas faixas de menor arrecadação. O MAE foi de US\$ 10,80 milhões na faixa muito baixa e de US\$ 15,03 milhões na faixa baixa, valores inferiores aos observados nos experimentos sem transformação da variável-alvo. Esse comportamento sugere que a compressão da escala ajudou o modelo a reduzir erros em casos mais frequentes da base.

Nas faixas superiores, porém, observa-se aumento da tendência de subestimação. Na faixa alta, 79,0% dos filmes foram subestimados, e, na faixa muito alta, esse percentual chegou a 82,5%, com resíduo médio de US\$ 134,15 milhões. Assim, a transformação logarítmica tornou o modelo mais conservador para filmes de maior arrecadação. Esse resultado ajuda a explicar por que houve melhora em MAE em parte da distribuição, mas não superação dos melhores resultados em RMSE e R^2 , que continuam mais sensíveis aos grandes desvios na cauda superior. Em outras palavras, o diagnóstico por faixa reforça a interpretação central da Seção 5: a dificuldade principal do problema permanece concentrada nos extremos superiores da distribuição.

A.3 Importância dos atributos com transformação logarítmica

Como etapa final desta análise complementar, foi calculada a importância por permutação para o *Random Forest Regressor* treinado com transformação logarítmica da variável-alvo, utilizando o MSE como métrica de avaliação. Essa etapa permite verificar se a configuração com $\log(1 + \text{receita})$ altera de forma relevante a leitura sobre os atributos usados pelo modelo.


A Figura 19 mostra que a hierarquia dos atributos

Table 12. Desempenho dos modelos com transformação logarítmica da variável-alvo, ordenados por RMSE. Os valores são apresentados como média $\pm$ desvio padrão ao longo dos 10 *folds*, com o melhor resultado de cada métrica destacado em negrito

Modelo	MSE [10^{16} US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
Random Forest Regressor	1,52 $\pm$ 0,35	122,50 $\pm$ 14,44	55,68 $\pm$ 2,47	0,560 $\pm$ 0,049
XGBoost Regressor	1,59 $\pm$ 0,43	124,87 $\pm$ 17,08	55,62 $\pm$ 2,94	0,545 $\pm$ 0,050
Gradient Boosting Regressor	1,66 $\pm$ 0,47	127,55 $\pm$ 18,30	56,33 $\pm$ 3,01	0,525 $\pm$ 0,061
Decision Tree Regressor	1,69 $\pm$ 0,35	129,47 $\pm$ 13,37	60,31 $\pm$ 2,32	0,506 $\pm$ 0,063
KNN Regressor	2,08 $\pm$ 0,46	143,27 $\pm$ 16,76	64,28 $\pm$ 2,87	0,400 $\pm$ 0,053
SVR	3,16 $\pm$ 1,38	174,03 $\pm$ 38,70	66,25 $\pm$ 5,67	0,052 $\pm$ 0,456
Dummy Regressor	3,97 $\pm$ 0,71	198,45 $\pm$ 18,58	87,04 $\pm$ 3,06	-0,153 $\pm$ 0,024
Linear Regression	4670,00 $\pm$ 9920,00	4284,38 $\pm$ 5615,12	260,40 $\pm$ 232,61	-1186,466 $\pm$ 2411,346

Table 13. Métricas do *Random Forest Regressor* com transformação logarítmica da variável-alvo por faixa de receita. Os intervalos seguem os mesmos cortes utilizados na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]	10,80	-10,33	14,0%
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]	15,03	-9,86	39,0%
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]	22,73	0,80	63,4%
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]	47,08	27,23	79,0%
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	182,69	134,15	82,5%

**Figure 19.** Importância média dos atributos por permutação para o *Random Forest Regressor* com transformação logarítmica da variável-alvo

permaneceu concentrada em variáveis estruturais, como orçamento, pertencimento a uma coleção e duração. Assim, embora a transformação logarítmica tenha modificado o comportamento dos erros em diferentes faixas de receita, a interpretação sobre os atributos mais relevantes para as previsões permaneceu semelhante àquela observada no cenário principal sem transformação.

Em síntese, este apêndice mostra que a transformação logarítmica melhora a aderência do modelo em parte das faixas de arrecadação, especialmente nas regiões inferiores da distribuição, mas não altera a conclusão central do artigo nem a leitura substantiva sobre os atributos mais relevantes. Por isso, os experimentos principais foram mantidos na escala original da receita, enquanto a análise com $\log(1 + \text{receita})$ permanece como evidência complementar para interpretar o papel da assimetria da variável-alvo.

B Investigação do desempenho do SVR sem transformação da variável-alvo

Este apêndice aprofunda um resultado pontual da Subseção 5.1: o comportamento atípico do *SVR* diante de uma variável-alvo fortemente assimétrica. O objetivo não

é reabrir a comparação principal entre todos os modelos, mas explicar por que o *SVR* permaneceu atrás das abordagens baseadas em árvores e *boosting* mesmo quando superou o *Dummy Regressor* em MAE. Dessa forma, o apêndice funciona como complemento interpretativo da discussão central de resultados.

Como mostrado na Tabela 4, o *SVR* obteve RMSE médio de US\$ 195,71 milhões, MAE médio de US\$ 86,55 milhões e R^2 médio de $-0,121$, enquanto o *Dummy Regressor* registrou RMSE médio de US\$ 184,99 milhões, MAE médio de US\$ 104,67 milhões e R^2 próximo de zero. Portanto, o *SVR* não foi inferior em todas as métricas, mas teve pior desempenho justamente nas medidas mais sensíveis a erros de grande magnitude. Isso mostra que sua limitação não está em errar mais em qualquer tipo de filme, mas em falhar de forma mais severa exatamente nos casos que mais pesam sobre o RMSE e sobre o R^2 .

Esse comportamento está diretamente relacionado à distribuição da receita. Como observado na Subseção 4.3, a variável-alvo apresenta forte assimetria à direita, com muitos filmes concentrados em faixas baixas ou intermediárias de arrecadação e poucos títulos com receitas extremamente elevadas. Nesse cenário, o *SVR* apresentou previsões com baixa variabilidade e concentradas em torno de valores centrais da distribuição. Isso ajuda a explicar o MAE menor que o do *Dummy Regressor*, pois muitos filmes da base estão mais próximos dessa região central do que de valores muito elevados de arrecadação. No entanto, para filmes de arrecadação muito alta, essa concentração gerou desvios elevados, aumentando o RMSE e reduzindo o R^2 . Como o MAE considera os desvios de forma linear, enquanto RMSE e R^2 são mais afetados por erros extremos, o modelo acaba parecendo relativamente aceitável em erro absoluto médio, mas pouco competitivo na comparação global.

A comparação com os experimentos com transformação logarítmica, apresentados na Tabela 12, reforça essa interpretação. Com $\log(1 + \text{receita})$, o *SVR* melhorou em relação à versão sem transformação, alcançando RMSE

médio de US\$ 174,03 milhões, MAE médio de US\$ 66,25 milhões e R^2 médio de 0,052. Ainda assim, seu desempenho permaneceu abaixo dos melhores modelos de *ensemble*, indicando que a transformação reduziu parte da dificuldade enfrentada pelo modelo, mas não foi suficiente para torná-lo competitivo com os melhores regressores avaliados. Em outras palavras, mesmo quando a assimetria da variável-alvo é parcialmente comprimida, o *SVR* continua sem alcançar o patamar das famílias que melhor lidaram com os extremos de arrecadação.

Em síntese, o desempenho limitado do *SVR* nos experimentos sem transformação da variável-alvo não indica ausência de informação nas variáveis explicativas, mas sim dificuldade do modelo em lidar diretamente com uma variável-alvo muito assimétrica e com valores extremos. Esse diagnóstico complementa a narrativa da Seção 5 ao mostrar, por contraste, por que os experimentos posteriores passaram a se concentrar nas famílias de modelos que já haviam demonstrado melhor capacidade de capturar não linearidades e de acomodar a heterogeneidade entre faixas de arrecadação.