

ARTIGO DE PESQUISA/RESEARCH PAPER

Uma Análise Comparativa de Modelos para Predição da Receita de Filmes

A Comparative Analysis of Models for Movie Revenue Prediction

Gabriel Prenassi ✉ [Universidade Federal de São João del-Rei | prenassigabriel@aluno.ufsj.edu.br]

✉ Departamento de Ciência da Computação, Universidade Federal de São João del-Rei, BR-494, s/n, Campus CTan, São João del-Rei, MG, 36301-360, Brasil.

Resumo. Este trabalho apresenta uma análise comparativa de modelos de regressão para prever a receita mundial de filmes a partir de metadados estruturados extraídos da API pública do TMDb. Foram considerados atributos como orçamento, duração, idioma original, gêneros e pertencimento a uma coleção, avaliando seu uso em um cenário de planejamento inicial. Os experimentos compararam diferentes regressores sob o mesmo protocolo experimental, incluindo modelos lineares, métodos baseados em vizinhança, árvores de decisão e técnicas de *ensemble*. A avaliação utilizou as métricas MSE, RMSE, MAE e R^2 , além de análises por faixa de receita e importância dos atributos. Os resultados indicaram melhor desempenho global do *XGBoost Regressor* treinado com a receita em sua escala original. A análise dos erros mostrou maior dificuldade em filmes de alta arrecadação, enquanto a importância dos atributos destacou orçamento, pertencimento a uma coleção e duração como variáveis mais relevantes.

Abstract. This work presents a comparative analysis of regression models for predicting the worldwide revenue of films using structured metadata extracted from the public TMDb API. Attributes such as budget, runtime, original language, genres, and collection membership were considered, evaluating their use in an early planning scenario. The experiments compared different regressors under the same experimental protocol, including linear models, neighborhood-based methods, decision trees, and *ensemble* techniques. The evaluation used the metrics MSE, RMSE, MAE, and R^2 , in addition to analyses by revenue range and attribute importance. The results indicated the best global performance for the *XGBoost Regressor* trained with revenue in its original scale. The error analysis showed greater difficulty in high-grossing films, while the attribute importance analysis highlighted budget, collection membership, and runtime as the most relevant variables.

Palavras-chave: Aprendizado de máquina, Regressão, Predição de receita, Filmes, TMDb

Keywords: Machine learning, Regression, Revenue prediction, Movies, TMDb

Recebido/Received: DD Month YYYY • Aceito/Accepted: DD Month YYYY • Publicado/Published: DD Month YYYY

1 Introdução

A predição da receita de filmes é um problema relevante no contexto da indústria cinematográfica, que se caracteriza por elevados custos de produção e forte incerteza quanto à demanda [Ghiassi *et al.*, 2015; Sharda and Delen, 2006]. Mesmo com investimentos expressivos, o sucesso financeiro de um filme permanece difícil de antecipar [Ahmad *et al.*, 2020b; Lash and Zhao, 2016]. Por esse motivo, modelos preditivos podem apoiar decisões relacionadas à seleção de projetos, definição de estratégias de lançamento, alocação de recursos e redução de riscos de investimento [Quader *et al.*, 2017; Lash and Zhao, 2016; Ghiassi *et al.*, 2015].

Estudos anteriores mostram que o desempenho financeiro de um filme pode ser influenciado por características da própria obra, como orçamento, duração, gênero, classificação indicativa e pertencimento a sequências [Ghiassi *et al.*, 2015; Sharda and Delen, 2006]. Além disso, fatores relacionados ao lançamento e à distribuição, como o grau de concorrência com outros filmes no mesmo período e a quantidade de salas de exibição, também aparecem na literatura como variáveis relevantes para a previsão de desempenho comercial [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Kim *et al.*, 2015].

Complementando esses atributos tradicionalmente

utilizados, abordagens mais recentes passaram a explorar informações extraídas de mídias sociais e plataformas *online*, como comentários em *trailers*, avaliações de usuários e menções em redes sociais, com o objetivo de captar indícios de interesse do público antes ou logo após o lançamento [Ahmad *et al.*, 2020a; Quader *et al.*, 2017; Kim *et al.*, 2015]. Outros estudos ainda incorporam dados multimodais, como informações visuais extraídas de pôsteres, ampliando o conjunto de evidências consideradas na previsão de desempenho financeiro [Madongo and Zhongjun, 2023; Zhou *et al.*, 2019]. Em conjunto, esses trabalhos evidenciam que o desempenho comercial de filmes pode ser estimado a partir de diferentes tipos de atributos e estratégias de modelagem [Mammadov *et al.*, 2025; Ahmad *et al.*, 2020b].

Nesse contexto, torna-se relevante investigar o potencial preditivo de informações estruturadas sobre os filmes, especialmente em fases iniciais de planejamento, quando ainda se avalia a viabilidade comercial de uma produção ou se comparam alternativas de projeto. Esse recorte permite analisar atributos que tendem a estar disponíveis previamente, antes da consolidação de sinais de recepção do público.

A partir desse recorte, este trabalho propõe uma análise comparativa de modelos de aprendizado de máquina para estimar a receita de filmes com base em dados extraídos

da API pública do *The Movie Database*¹ (TMDb), uma plataforma *online* que disponibiliza metadados estruturados sobre produções audiovisuais, incluindo informações como título, idioma original, duração, gêneros, pertencimento a uma coleção, orçamento e receita.

Com base nesse conjunto de informações, a tarefa é formulada como um problema de regressão supervisionada, no qual a receita mundial arrecadada por cada filme é estimada a partir dos atributos disponíveis na base. Assim, o estudo é orientado pelas seguintes perguntas de pesquisa:

- QP1.** Em que medida metadados estruturados de filmes podem ser utilizados para estimar a receita mundial arrecadada pelas obras?
- QP2.** Quais modelos de regressão apresentam melhor desempenho na predição da receita de filmes sob um mesmo protocolo experimental?
- QP3.** Como os erros de predição se comportam ao longo das diferentes faixas de receita?
- QP4.** Quais atributos considerados no estudo apresentam maior contribuição para a predição da receita dos filmes?

Para responder a essas questões, diferentes regressores são comparados a uma linha de base simples e avaliados sob o mesmo protocolo experimental, incluindo modelos lineares, métodos baseados em vizinhança, árvores de decisão e técnicas de *ensemble*. A avaliação utiliza validação cruzada e métricas de regressão, como MSE, RMSE, MAE e R^2 .

Além da comparação global de desempenho, o estudo investiga o comportamento dos erros em diferentes faixas de receita e examina a contribuição dos atributos por meio de análise de importância. Com isso, busca-se identificar não apenas quais modelos apresentam melhor desempenho preditivo, mas também em quais situações a predição se torna mais limitada e quais características dos filmes mais influenciam as estimativas. Essa análise é especialmente relevante diante da alta variabilidade da arrecadação cinematográfica, aspecto já apontado na literatura como um desafio para a previsão de desempenho financeiro de filmes [Ahmad *et al.*, 2020b; Ghiassi *et al.*, 2015] e também observado na base utilizada neste estudo, conforme apresentado na Subseção 4.3.

Como análise complementar, também são examinados os efeitos da transformação logarítmica da variável-alvo. Essa análise busca verificar se a compressão dos valores extremos altera as conclusões dos experimentos sem transformação da variável-alvo, nos quais a receita é mantida em sua escala original. Os resultados dessa avaliação são apresentados no Apêndice A.

2 Trabalhos Relacionados

A predição do desempenho financeiro de filmes tem sido investigada a partir de diferentes formulações, como estimativa de receita, previsão de lucratividade e classificação de sucesso comercial [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Ghiassi *et al.*, 2015; Sharda and Delen, 2006]. Embora esses estudos variem quanto à variável-alvo e aos métodos utilizados, é comum que explorem atributos relacionados à própria obra, como gênero, orçamento, duração, elenco

e pertencimento a sequências, além de fatores associados ao lançamento e à distribuição, como período de estreia, número de salas de exibição e concorrência com outros filmes [Ahmad *et al.*, 2020b; Lash and Zhao, 2016; Kim *et al.*, 2015]. Assim, a literatura indica que o desempenho comercial de filmes pode ser analisado a partir de diferentes fontes de informação, dependendo do momento em que a previsão é realizada e dos dados disponíveis para a modelagem.

Entre os trabalhos voltados a previsões antes do lançamento ou em fases iniciais, há estudos que utilizam principalmente atributos conhecidos antes da consolidação da recepção do público. O sucesso de bilheteria já foi tratado como uma tarefa de classificação em faixas de desempenho, considerando características como gênero, classificação indicativa, presença de sequência, efeitos especiais, competição e número de telas [Sharda and Delen, 2006]. A previsão de receita em pré-produção também foi investigada a partir de variáveis como orçamento, gastos de publicidade pré-lançamento, duração e sazonalidade [Ghiassi *et al.*, 2015]. De forma semelhante, a previsão de lucratividade em estágios iniciais foi abordada por meio da combinação de informações sobre participantes, conteúdo e momento de lançamento [Lash and Zhao, 2016]. Esses trabalhos mostram que atributos disponíveis antes da resposta efetiva do público podem fornecer indícios relevantes sobre o potencial comercial de uma produção, embora utilizem diferentes conjuntos de dados, variáveis de entrada e objetivos preditivos.

Outra linha de pesquisa busca ampliar a capacidade preditiva dos modelos por meio de sinais gerados em plataformas *online*. Dados de redes sociais já foram utilizados na previsão de bilheteria, indicando que manifestações do público podem contribuir para estimar o desempenho comercial [Kim *et al.*, 2015]. Comentários em *trailers* no YouTube também foram explorados para identificar sinais de interesse do público e prever receita [Ahmad *et al.*, 2020a]. Além disso, outros estudos combinam fontes como *IMDb*, *Rotten Tomatoes*, *Box Office Mojo* e *Metacritic*, incorporando atributos disponíveis antes e depois do lançamento [Quader *et al.*, 2017]. Essas abordagens evidenciam que comentários, avaliações e medidas de engajamento podem complementar os metadados tradicionais, mas dependem de exposição prévia ao público ou de informações que nem sempre estão disponíveis em fases iniciais de planejamento.

Mais recentemente, também foram exploradas abordagens com dados multimodais e métodos voltados à interpretação dos modelos. Redes neurais profundas multimodais foram utilizadas para combinar metadados dos filmes com informações visuais extraídas de pôsteres [Zhou *et al.*, 2019]. Outra abordagem investigou a predição de receita a partir da combinação entre metadados e atributos visuais extraídos de pôsteres, utilizando aprendizado profundo e transferência de aprendizado [Madongo and Zhongjun, 2023]. Além disso, a previsão de sucesso de bilheteria foi analisada com técnicas de inteligência artificial explicável, buscando identificar fatores associados à lucratividade [Mammadov *et al.*, 2025]. Esses estudos ampliam o conjunto de evidências usado na predição, mas também dependem de fontes adicionais ou representações mais complexas, como imagens, sinais de engajamento e técnicas específicas de interpretação.

Diante desse cenário, embora previsões em etapas ante-

¹Disponível em: <https://www.themoviedb.org/>

riores ou próximas ao lançamento já tenham sido exploradas na literatura, e atributos básicos dos filmes, como orçamento, duração, gênero e pertencimento a sequências, já tenham sido apontados como relevantes, este trabalho concentra sua análise em um conjunto reduzido de atributos estruturados associados à caracterização inicial das obras. Como apresentado na Subseção 4.1, são consideradas informações como orçamento, duração, idioma original, gêneros e pertencimento a uma coleção, evitando atributos que dependam de decisões mais avançadas de produção, da definição do elenco, de sinais de recepção do público ou de dados posteriores ao lançamento.

Com isso, busca-se aproximar a análise de um cenário de planejamento preliminar, no qual ainda se comparam possíveis projetos e se avalia sua viabilidade comercial com base em informações limitadas. Nesse sentido, a contribuição do trabalho está em comparar diferentes regressores sob um mesmo protocolo experimental, examinando não apenas o desempenho global dos modelos, mas também o comportamento dos erros por faixas de receita e a importância dos atributos.

3 Fundamentação Teórica

O aprendizado de máquina é uma área da inteligência artificial voltada ao desenvolvimento de métodos capazes de identificar padrões em dados e utilizá-los para realizar previsões, classificações ou outras formas de inferência [James *et al.*, 2023; Murphy, 2022]. Em problemas de aprendizado supervisionado, os modelos são treinados a partir de exemplos nos quais as variáveis de entrada estão associadas a uma saída conhecida, buscando generalizar essa relação para novos dados [James *et al.*, 2023].

Neste trabalho, o problema é formulado como uma tarefa de regressão, pois o objetivo é estimar a receita mundial dos filmes a partir de atributos descritivos e financeiros. Como a variável-alvo corresponde a um valor numérico contínuo, a regressão busca estimar valores contínuos a partir dos atributos de entrada, diferentemente de problemas de classificação, nos quais a saída pertence a um conjunto discreto de classes [James *et al.*, 2023].

3.1 Modelos de regressão

Considerando a formulação do problema como regressão, foram selecionados modelos com diferentes níveis de complexidade, tomando como base algoritmos recorrentes na literatura de predição de receita, popularidade e desempenho comercial de filmes [Udandarao and Gupta, 2024; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. A comparação parte de linhas de base simples e avança até métodos mais flexíveis, permitindo observar em que medida o aumento de complexidade contribui para capturar padrões associados à arrecadação dos filmes. Além dos modelos preditivos propriamente ditos, utiliza-se o *Dummy Regressor* como referência mínima de desempenho, pois esse modelo não aprende relações entre os atributos e a variável-alvo e produz estimativas fixas, como a média ou a mediana observada no conjunto de treinamento.

Entre os modelos mais simples, a Regressão Linear é utilizada como referência por buscar uma relação linear entre os atributos de entrada e a receita. Diferentemente do *Dummy Regressor*, esse modelo incorpora efetivamente as variáveis explicativas no processo de predição, permitindo verificar se uma estrutura linear já é suficiente para representar parte do

comportamento da variável-alvo. Modelos lineares aparecem em estudos de predição de receita de filmes e são usados como ponto de comparação para abordagens mais flexíveis [Udandarao and Gupta, 2024; Ahmad *et al.*, 2020b].

Em seguida, são avaliados modelos com estratégias distintas de predição, como o *KNN Regressor* e o *SVR*. O *KNN Regressor* estima a receita com base na similaridade entre instâncias, partindo da ideia de que filmes com características semelhantes tendem a apresentar comportamentos comerciais próximos. Modelos baseados em *KNN* aparecem em estudos de predição de receita e popularidade de filmes [Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. Já o *SVR* adapta as máquinas de vetores de suporte para regressão, buscando ajustar as previsões de modo a controlar os desvios em relação aos valores observados. Máquinas de vetores de suporte também são recorrentes na literatura de predição de receita de filmes [Ahmad *et al.*, 2020b].

Para capturar relações não lineares, também são considerados modelos baseados em árvores. A Árvore de Decisão divide o espaço dos atributos em regiões e realiza predições a partir dessas divisões, permitindo representar interações mais complexas entre as variáveis. Árvores de decisão são utilizadas em estudos de predição de receita, popularidade ou sucesso de filmes [Udandarao and Gupta, 2024; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. A *Random Forest*, por sua vez, combina várias árvores treinadas sobre diferentes amostras dos dados, reduzindo a instabilidade típica de uma única árvore e produzindo estimativas mais robustas. Esse modelo também aparece em estudos comparativos sobre predição de desempenho de filmes [Udandarao and Gupta, 2024; Abidi *et al.*, 2020].

Por fim, são avaliados métodos de *ensemble* baseados em *boosting*, como *Gradient Boosting* e *XGBoost*. Nessa abordagem, vários modelos simples, geralmente árvores de decisão rasas, são treinados de forma sequencial, de modo que cada novo ajuste procure reduzir erros acumulados nas etapas anteriores. Como resultado, a predição final passa a refletir a combinação progressiva dessas correções, o que favorece a captura de relações não lineares e interações entre atributos. Esse tipo de estratégia é particularmente relevante em bases tabulares heterogêneas, como a utilizada neste trabalho, descrita na Subseção 4.1. *Gradient Boosting* e *XGBoost* aparecem em estudos de predição de receita e popularidade de filmes, sendo comparados com modelos como Regressão Linear, Árvore de Decisão e *Random Forest* [Udandarao and Gupta, 2024; Abidi *et al.*, 2020].

3.2 Métricas e procedimentos de avaliação

Assim como na seleção dos modelos, a escolha das métricas de avaliação considera medidas recorrentes na literatura de predição de receita, popularidade e desempenho comercial de filmes [Udandarao and Gupta, 2024; Gupta *et al.*, 2023; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]. Como o problema é tratado como regressão, essas métricas quantificam a diferença entre os valores reais e os valores previstos, permitindo avaliar o quanto as estimativas dos modelos se aproximam da receita observada. Como as predições são avaliadas na escala original da receita, métricas como MAE e RMSE permanecem diretamente interpretáveis em termos monetários, inclusive nos

experimentos complementares em que o treinamento utiliza a transformação logarítmica e as previsões são posteriormente reconvertidas para dólares. Considerando n instâncias, em que y_i representa o valor real da receita e $\hat{y}_i$ representa o valor previsto pelo modelo, uma das métricas adotadas é o Erro Absoluto Médio, ou *Mean Absolute Error* (MAE):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (1)$$

O MAE corresponde à média das diferenças absolutas entre valores reais e previstos. Por estar na mesma unidade da variável-alvo, essa métrica permite interpretar diretamente o erro médio das predições em termos monetários. Além disso, como considera os erros em valor absoluto, o MAE fornece uma medida geral da magnitude dos desvios, sem indicar se o modelo tende a superestimar ou subestimar a receita.

Também é considerado o Erro Quadrático Médio, ou *Mean Squared Error* (MSE), que calcula a média dos erros ao quadrado e penaliza mais fortemente erros de maior magnitude. Essa métrica também aparece em avaliações de erro preditivo nesse domínio [Gupta *et al.*, 2023; Ahmad *et al.*, 2020b]:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2)$$

Por elevar os erros ao quadrado, o MSE atribui maior peso a grandes desvios entre a receita real e a prevista. Essa característica é relevante neste trabalho, pois a análise exploratória da base de dados, apresentada na Subseção 4.3, evidencia que a receita dos filmes apresenta alta variabilidade e presença de valores extremos. Assim, modelos que cometem erros muito elevados em filmes de grande arrecadação tendem a ser mais penalizados por essa métrica.

A Raiz do Erro Quadrático Médio, ou *Root Mean Squared Error* (RMSE), corresponde à raiz quadrada do MSE e mantém a interpretação do erro na mesma unidade da variável-alvo. Essa métrica é recorrente em trabalhos de regressão para predição de receita, popularidade ou desempenho de filmes [Gupta *et al.*, 2023; Ahmad *et al.*, 2020b; Abidi *et al.*, 2020]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3)$$

O RMSE combina duas propriedades importantes: mantém a sensibilidade a grandes erros, herdada do MSE, e permite interpretar o resultado na mesma escala da receita. Por esse motivo, é útil para comparar modelos em cenários nos quais erros elevados são especialmente importantes, como na predição de filmes com arrecadação muito acima do comportamento médio da base.

Além das métricas de erro, o coeficiente de determinação, representado por R^2 , é adotado para avaliar a qualidade do ajuste dos regressores, como ocorre em estudos de predição de receita de filmes [Udandara and Gupta, 2024]. Considerando $\bar{y}$ como a média dos valores reais, o R^2 é definido por:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (4)$$

Diferentemente das métricas de erro, em que valores menores indicam melhor desempenho, o R^2 mede a proporção da variabilidade da variável-alvo explicada pelo modelo. Valores mais próximos de 1 indicam maior capacidade explicativa, enquanto valores próximos ou inferiores a 0 indicam desempenho baixo em relação a uma estratégia simples baseada na média dos valores observados. Assim, o uso conjunto de MAE, MSE, RMSE e R^2 permite avaliar os modelos sob perspectivas complementares: magnitude média dos desvios, penalização de grandes erros, interpretação direta na escala monetária da receita e qualidade geral do ajuste.

3.3 Interpretação dos erros e importância dos atributos

Além das métricas quantitativas agregadas, a análise dos erros de predição permite observar o comportamento dos modelos sob outras perspectivas. Em tarefas de regressão, os resíduos correspondem à diferença entre os valores reais e os valores previstos, permitindo identificar padrões de superestimação ou subestimação [James *et al.*, 2023]. Quando o resíduo é definido como *real* – *predito*, valores negativos indicam que o modelo previu uma receita maior que a observada, enquanto valores positivos indicam que a receita foi subestimada. Já os erros absolutos permitem avaliar a magnitude dos desvios cometidos pelo modelo, independentemente da direção do erro.

No contexto da predição de receita de filmes, essa leitura é especialmente relevante devido à alta variabilidade da variável-alvo, aspecto também observado na base utilizada neste estudo, conforme apresentado na Subseção 4.3. Essa variabilidade faz com que filmes de diferentes níveis de arrecadação possam apresentar dificuldades distintas para os modelos, tornando útil examinar os erros também por faixas de receita definidas ao longo da distribuição da variável-alvo [Ahmad *et al.*, 2020b; Ghiassi *et al.*, 2015].

A interpretação dos modelos também pode ser complementada pela análise da importância dos atributos. Uma técnica utilizada para esse fim é a *Permutation Feature Importance*, que estima a relevância de uma variável a partir da queda de desempenho observada quando seus valores são embaralhados. De forma geral, calcula-se primeiro o desempenho do modelo com os dados originais. Em seguida, os valores de um atributo são permutados entre as instâncias, rompendo sua associação com a variável-alvo, enquanto os demais atributos permanecem inalterados. Se essa alteração provoca queda expressiva no desempenho, entende-se que o atributo possui maior importância para as predições. Essa técnica é útil para inspecionar modelos preditivos, especialmente quando se deseja compreender melhor quais características efetivamente sustentam a estimativa da receita em modelos menos transparentes. Essa preocupação com interpretabilidade também aparece em estudos recentes sobre previsão de sucesso de bilheteria com técnicas de inteligência artificial explicável [Mammadov *et al.*, 2025].

4 Metodologia Experimental

4.1 Base de dados

A base de dados utilizada neste trabalho foi obtida por meio de consultas realizadas à API pública do TMDB. Na etapa inicial de coleta, foram efetuadas 1.000 requisições,

sendo que cada uma retornava 20 filmes, resultando em 20.000 registros inicialmente recuperados. A partir dessas consultas, foram obtidas informações estruturadas sobre cada obra, incluindo atributos de identificação, características descritivas e informações financeiras relevantes para a análise proposta. A Tabela 1 apresenta os atributos coletados a partir da API, incluindo informações de identificação, características descritivas e dados financeiros das obras.

Conforme discutido anteriormente, para a tarefa de regressão considerada neste trabalho, a receita mundial é definida como variável-alvo, enquanto idioma original, indicador de conteúdo adulto, gêneros, pertencimento a uma coleção, duração e orçamento são considerados variáveis de entrada. Embora a base seja composta por filmes já lançados, esses atributos são interpretados, no contexto da análise, como metadados estruturados e características que poderiam ser conhecidas ou estimadas em fases iniciais de planejamento, anteriores ao lançamento, com o objetivo de avaliar sua contribuição para a estimativa do potencial comercial das obras.

Tabela 1. Descrição dos atributos coletados da base de dados do TMDb

Atributo	Descrição
ID (identificação)	Identificador único do filme na base de dados do TMDb.
Título (identificação)	Título original do filme, sem tradução.
Idioma original (categórico)	Código do idioma original do filme, por exemplo, <i>en</i> para inglês.
Indicador de conteúdo adulto (binário)	Informa se o filme está marcado na base como conteúdo adulto.
Vídeo (binário)	Informa se a entrada corresponde a um vídeo, como <i>trailer</i> ou clipe.
Gêneros (categórico)	Lista com os gêneros associados ao filme, como ação, drama ou comédia.
Situação de lançamento (categórico)	Status atual do lançamento, como <i>Released</i> ou <i>Post Production</i> .
Duração (numérico contínuo)	Tempo de execução do filme, em minutos.
Coleção (categórico)	Indica se o filme pertence a uma franquia ou coleção.
Orçamento (numérico contínuo)	Estimativa do valor gasto na produção, em US\$.
Receita (numérico contínuo)	Receita mundial total arrecadada, em US\$.

4.2 Pré-processamento

Dos 20.000 registros inicialmente obtidos, 6.233 correspondiam a filmes duplicados. Assim, apenas um exemplar de cada obra foi mantido na base, resultando em 13.767 registros únicos. Em seguida, foram verificados os valores faltantes, admitindo-se ausência apenas na variável referente ao pertencimento a uma coleção, uma vez que, nesse caso, a própria API pode retornar valor nulo para filmes que não pertencem a nenhuma franquia ou coleção. Essa etapa, porém, não implicou remoção adicional de registros.

Posteriormente, realizou-se uma filtragem complementar com o objetivo de manter apenas instâncias compatíveis com a análise proposta. Para isso, foram preservados somente os filmes com valores maiores que zero para orçamento, receita e duração, assegurando a validade dessas variáveis numéricas. Também foram mantidos apenas registros com lista não vazia de gêneros, excluindo-se obras com

informação incompleta nesse atributo. Além disso, foram removidas entradas classificadas como vídeo, tais como *trailers* e clipes, de modo que a base final contemplasse exclusivamente filmes. Por fim, restringiu-se o conjunto às obras com status “*Released*”, isto é, efetivamente lançadas.

Após essas etapas de tratamento e filtragem, a base final passou a ser composta por 6.918 filmes, correspondendo ao conjunto de dados utilizado no desenvolvimento dos experimentos.

4.3 Análise exploratória dos dados

Após a definição da base final, foi realizada uma análise exploratória com o objetivo de examinar a distribuição dos principais atributos utilizados no estudo, identificar padrões gerais da base e observar características que poderiam influenciar a tarefa de predição da receita. Essa etapa também foi importante para orientar decisões posteriores do protocolo experimental, especialmente em função da forte assimetria observada na variável-alvo.

Com relação ao idioma original, a base final contém filmes em 47 idiomas diferentes. A Figura 1 apresenta os 20 idiomas mais frequentes, evidenciando a predominância do inglês, presente em 5.963 filmes, o que corresponde a aproximadamente 86,2% da base. Em seguida, aparecem o francês, com 243 filmes, e o hindi, com 108. Esse comportamento indica forte concentração de obras cujo idioma original é o inglês, embora ainda exista diversidade linguística suficiente para manter esse atributo na modelagem.




Figura 1. Frequência dos idiomas originais presentes na base de dados

No caso dos gêneros, um mesmo filme pode estar associado a mais de uma categoria. Ao todo, foram identificados 19 gêneros distintos na base. A Figura 2 mostra que *Drama*, *Comedy*, *Thriller* e *Action* são os gêneros mais frequentes, com 3.186, 2.414, 1.953 e 1.847 ocorrências, respectivamente. Por outro lado, gêneros como *Documentary* e *TV Movie* aparecem com frequência menor. Como os filmes podem possuir múltiplos gêneros, a soma das frequências ultrapassa o total de registros da base.

Quanto ao pertencimento a coleções ou franquias, observa-se que 5.014 filmes não pertencem a nenhuma coleção, enquanto 1.904 pertencem a alguma franquia. Assim, aproximadamente 72,5% da base é composta por filmes sem vínculo com coleção. Esse atributo é relevante para a análise, pois filmes associados a franquias podem apresentar padrões específicos de orçamento, expectativa de público e arrecadação.

A duração dos filmes apresenta média de aproximadamente 110,9 minutos e desvio padrão de cerca de 21,2




Figura 2. Frequência dos gêneros presentes na base de dados

minutos. O menor valor observado foi de 5 minutos, enquanto o maior chegou a 254 minutos. Em termos de quartis, 25% dos filmes possuem até 96 minutos de duração, 50% até 107 minutos e 75% até 121 minutos. Esses resultados indicam que a maior parte das obras está concentrada em durações típicas de longas-metragens convencionais.

A Figura 3 mostra que a distribuição da duração é assimétrica à direita, com maior concentração de filmes entre 80 e 120 minutos e pico próximo de 100 minutos. Esse comportamento também é observado no *boxplot* da Figura 4, que evidencia a presença de alguns valores atípicos, principalmente entre filmes mais longos.




Figura 3. Distribuição referente à variável duração




Figura 4. *Boxplot* referente à variável duração

Com relação ao orçamento, os filmes apresentam média de aproximadamente 33,9 milhões de dólares e desvio padrão de cerca de 44,2 milhões, evidenciando alta dispersão. O menor orçamento registrado foi de 1 dólar, enquanto o maior chegou a 465,4 milhões. A mediana foi de 19 milhões de dólares, enquanto 75% dos filmes possuem orçamento de até 40 milhões. Portanto, embora existam produções de custo muito elevado, a maior parte da base concentra-se em faixas mais baixas ou intermediárias de orçamento.

A distribuição do orçamento, apresentada na Figura 5, possui forte assimetria à direita. O *boxplot* da Figura 6 reforça esse padrão ao evidenciar diversos *outliers*, correspondentes a produções com investimentos muito superiores ao comportamento central da base.




Figura 5. Distribuição referente à variável orçamento




Figura 6. *Boxplot* referente à variável orçamento

A receita, definida como variável-alvo da regressão, apresenta média de aproximadamente 99,0 milhões de dólares e desvio padrão de cerca de 185,9 milhões. O menor valor registrado foi de 1 dólar, enquanto o maior alcançou aproximadamente 2,92 bilhões de dólares. A mediana foi de cerca de 35,2 milhões, e 75% dos filmes arrecadaram até aproximadamente 104,0 milhões. Esses valores mostram que a receita possui dispersão elevada e presença de arrecadações extremas.

A Figura 7 mostra que a distribuição da receita é fortemente assimétrica à direita, com grande concentração de filmes em faixas mais baixas de arrecadação e uma cauda longa formada por poucos filmes de receita muito elevada. O *boxplot* da Figura 8 confirma a presença expressiva de *outliers*. Esse comportamento é importante para a modelagem, pois indica que a predição da receita envolve lidar com uma variável-alvo muito assimétrica e com grande variabilidade entre os filmes. Essa característica motivou a construção de partições equilibradas por faixas de arrecadação, a análise posterior dos erros segundo esses mesmos intervalos e a avaliação complementar com transformação logarítmica da variável-alvo, apresentada no Apêndice A.

4.4 Validação dos modelos

A avaliação dos modelos foi realizada por validação cruzada estratificada com 10 *folds*. Como o problema é de regressão e a receita apresenta distribuição bastante desigual, conforme apresentado na Subseção 4.3, a estratificação foi feita a partir de cinco faixas da variável-alvo definidas por quantis. Esse procedimento foi adotado para distribuir de forma mais




Figura 7. Distribuição referente à variável receita




Figura 8. Boxplot referente à variável receita

equilibrada filmes com diferentes níveis de arrecadação entre as partições. Em cada iteração, um *fold* foi reservado para teste e os demais foram utilizados para treinamento.

A Tabela 2 apresenta os intervalos de receita utilizados na estratificação. Como apenas filmes com receita positiva foram mantidos na base, a primeira faixa se inicia em US\$ 1. Os intervalos são fechados à direita e abertos à esquerda, exceto a primeira faixa, que inclui o menor valor observado. Observa-se que as faixas possuem quantidades praticamente iguais de filmes, variando entre 1.383 e 1.384 instâncias, o que contribui para uma avaliação mais equilibrada ao longo da distribuição da variável-alvo.

Tabela 2. Faixas de receita utilizadas na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]

As mesmas divisões da validação cruzada foram utilizadas em todos os experimentos deste recorte, incluindo a análise complementar com transformação logarítmica apresentada no Apêndice A. Com isso, os regressores foram comparados sob as mesmas condições. Os cortes definidos por faixas de receita também foram preservados para a análise posterior dos erros do modelo selecionado, apresentada na Subseção 5.2, e para a análise por faixas no Apêndice A. Dessa forma, as diferenças observadas nos resultados refletem principalmente o comportamento dos modelos diante da mesma base e do mesmo protocolo de avaliação, e não variações ocasionais na forma como os dados foram separados.

4.5 Ajuste de hiperparâmetros

O ajuste de hiperparâmetros foi realizado por meio de *Grid Search*, a partir de conjuntos pré-definidos de configurações para cada regressor. Como a avaliação utilizou validação cruzada com 10 *folds*, a busca por hiperparâmetros foi executada separadamente em cada uma das 10 iterações. Em cada iteração, o *Grid Search* foi conduzido exclusivamente sobre os dados de treinamento, preservando o *fold* de teste para a avaliação final do modelo naquela partição.

A seleção da melhor configuração em cada iteração foi feita com base no menor erro quadrático médio, ou *Mean Squared Error* (MSE), obtido em uma partição interna de validação (*holdout*) extraída do conjunto de treinamento. Esse critério foi adotado porque o MSE penaliza mais fortemente desvios de grande magnitude, o que é particularmente relevante em uma tarefa na qual a variável-alvo apresenta alta variabilidade e presença de valores extremos, conforme observado na análise exploratória apresentada na Subseção 4.3.

Os conjuntos de hiperparâmetros avaliados no *Grid Search* contemplaram alternativas compatíveis com a lógica de funcionamento de cada família de modelos, variando desde configurações mais simples até opções com maior flexibilidade preditiva. Com isso, buscou-se comparar os regressores não apenas em uma parametrização fixa, mas em versões ajustadas de maneira coerente com suas características. O mesmo procedimento de ajuste foi adotado nos experimentos complementares com transformação logarítmica da variável-alvo, apresentados no Apêndice A. A lista completa de valores avaliados pode ser consultada no repositório do projeto.

4.6 Análise dos erros e da importância dos atributos

Após a comparação global dos modelos sem transformação da variável-alvo, foram realizadas análises adicionais com o objetivo de examinar o comportamento dos erros de predição e a contribuição dos atributos. Essas análises foram conduzidas com base no modelo de melhor desempenho global nesses experimentos, selecionado a partir da comparação conjunta das métricas de avaliação, considerando menores valores de MSE, RMSE e MAE, além de maior valor de R^2 . Para a análise dos erros, foram considerados os resíduos, definidos como a diferença entre a receita real e a receita prevista, bem como os erros absolutos obtidos por esse modelo. A proporção de subestimações foi calculada como o percentual de casos em que a receita real foi maior que a receita prevista, isto é, quando o resíduo *real* – *predito* foi positivo. De forma complementar, resíduos negativos indicam superestimação. Esses valores foram analisados em relação às faixas de receita dos filmes, permitindo verificar se a dificuldade de predição varia entre obras de baixa, média e alta arrecadação.

Por fim, foi investigada a contribuição dos atributos para as predições do modelo selecionado. Para isso, foi aplicada a técnica de *Permutation Feature Importance*, utilizando o MSE como métrica de avaliação. Nessa análise, observa-se quanto o erro quadrático médio do modelo aumenta quando os valores de cada atributo são embaralhados. Assim, atributos cuja permutação provoca maior aumento no MSE são interpretados como mais relevantes para as predições.

Nos experimentos complementares com transformação logarítmica da variável-alvo, apresentados no Apêndice A,

também foram analisados os erros por faixa de receita e a importância dos atributos, seguindo os mesmos critérios descritos nesta subseção e considerando o modelo de melhor desempenho nessa configuração.

5 Resultados e Discussão

5.1 Comparação global entre os modelos sem transformação da variável-alvo

A Tabela 3 apresenta os resultados obtidos nos experimentos sem transformação da variável-alvo, em que a receita foi mantida em sua escala original, ao longo dos 10 *folds*, expressos como média e desvio padrão. Esses resultados mostram que os metadados estruturados utilizados neste trabalho possuem capacidade preditiva para a estimação da receita mundial dos filmes, uma vez que os melhores modelos superaram com folga a linha de base simples representada pelo *Dummy Regressor*. Entre os regressores avaliados, o *XGBoost Regressor* apresentou o melhor desempenho global, pois reuniu os resultados mais favoráveis na comparação conjunta das métricas, com menores valores de MSE, RMSE e MAE e maior valor de R^2 . Por esse motivo, esse modelo foi adotado como referência nas análises de erro e de importância dos atributos apresentadas nas subseções seguintes.

Mais especificamente, o *XGBoost Regressor* atingiu MSE médio de $1,39 \times 10^{16}$, RMSE médio de US\$ 117,32 milhões, MAE médio de US\$ 58,94 milhões e $R^2 = 0,594$. Esses valores indicam que o modelo foi o mais consistente na comparação global: apresentou os menores erros médios e, ao mesmo tempo, a maior capacidade de explicar a variação da receita em relação a uma estratégia baseada na média. O RMSE, por penalizar mais fortemente grandes desvios, mostra que o *XGBoost Regressor* também foi o modelo mais adequado quando se considera a presença de filmes com arrecadações muito elevadas. Já o MAE indica que, em média, suas previsões se afastaram da receita real em cerca de US\$ 58,94 milhões.

Em seguida, aparecem o *Random Forest Regressor* e o *Gradient Boosting Regressor*, ambos com desempenho bastante próximo ao *XGBoost Regressor*. Esse resultado reforça a adequação de métodos de *ensemble* baseados em árvores para o problema, pois esses modelos conseguem capturar relações não lineares e interações entre atributos como orçamento, coleção, duração, gênero, idioma e receita. A *Linear Regression* também apresentou desempenho competitivo em MSE, RMSE e R^2 , o que sugere que parte da relação entre os atributos e a receita pode ser capturada por uma estrutura mais simples. No entanto, seu MAE mais elevado indica que, em média, seus erros absolutos foram maiores que os dos três melhores modelos. Já o SVR apresentou desempenho limitado: embora tenha obtido MAE menor que o *Dummy Regressor*, seu RMSE foi maior e seu R^2 foi negativo, indicando pior desempenho nas métricas mais sensíveis a grandes desvios. Esse comportamento é discutido de forma complementar no Apêndice B.

Como análise complementar, também foram avaliados modelos com transformação logarítmica da variável-alvo, apresentados no Apêndice A. Nessa configuração, a receita foi transformada por meio de $\log(1 + \text{receita})$ durante o treinamento, e as previsões foram posteriormente convertidas

de volta para a escala original antes do cálculo das métricas. Os resultados indicaram redução do MAE em alguns modelos, mas não superaram os experimentos sem transformação da variável-alvo em RMSE e R^2 . Dessa forma, considerando o menor RMSE, o maior R^2 e um MAE ainda próximo ao melhor valor observado, o *XGBoost Regressor* treinado sem transformação da variável-alvo foi mantido como o melhor modelo global.

Esses achados respondem diretamente às QP1 e QP2. A QP1 é respondida ao mostrar que os metadados estruturados permitem estimar parcialmente a receita dos filmes, uma vez que diversos modelos superaram a linha de base simples representada pelo *Dummy Regressor*. Já a QP2 é respondida pela comparação direta entre os regressores, que aponta o *XGBoost Regressor* sem transformação da variável-alvo como o melhor modelo geral do estudo.

5.2 Análise dos erros por faixa de receita

Após a seleção do *XGBoost Regressor* como melhor modelo global nos experimentos sem transformação da variável-alvo, foi realizada uma análise dos erros por faixa de receita. Para isso, foram retomados os mesmos cortes definidos na etapa de estratificação da validação cruzada, conforme apresentado na Subseção 4.4. Esses cortes dividem a variável-alvo em cinco faixas de arrecadação praticamente balanceadas, permitindo avaliar se o comportamento do modelo varia entre filmes de menor, média e maior receita. Dessa forma, a análise possibilita observar em quais regiões da distribuição o modelo apresenta maior dificuldade de predição, especialmente nos casos de arrecadação mais elevada.

A Tabela 4 apresenta os resultados por faixa. O padrão mais evidente é o aumento do erro absoluto médio nas faixas superiores. Nas três primeiras faixas, o MAE permanece entre US\$ 26,50 milhões e US\$ 32,40 milhões. Na faixa alta, esse valor sobe para US\$ 41,33 milhões. Na faixa muito alta, porém, ocorre um salto expressivo para US\$ 163,44 milhões. Esse contraste mostra que a maior dificuldade do problema está concentrada justamente na cauda superior da distribuição, composta por filmes de arrecadação mais elevada.

Além da magnitude dos erros, a Tabela 4 também permite observar sua direção. O resíduo médio corresponde à média das diferenças entre a receita real e a receita prevista pelo modelo, isto é, *real* – *predito*. Portanto, valores negativos indicam superestimação, enquanto valores positivos indicam subestimação. Nas faixas muito baixa, baixa e média, predominam superestimações, pois os resíduos médios são negativos e a proporção de subestimações permanece abaixo de 50%. Na faixa alta, observa-se uma região de transição: embora 59,0% dos filmes sejam subestimados, o resíduo médio ainda fica próximo de zero e ligeiramente negativo, indicando maior equilíbrio entre superestimações e subestimações. Já na faixa muito alta, o padrão se inverte com maior clareza, com resíduo médio de US\$ 83,54 milhões e 71,7% de subestimações.

Esse comportamento indica que o modelo apresenta dificuldade para representar os extremos da distribuição da receita. Nas faixas de menor arrecadação, as previsões tendem a ficar acima dos valores reais, enquanto, na faixa muito alta, tendem a ficar abaixo dos valores observados. Assim, o modelo aproxima melhor os casos mais centrais da base, mas tem menor capacidade de acompanhar filmes


Tabela 3. Desempenho dos modelos na predição da receita sem transformação da variável-alvo, ordenados por RMSE. Os valores são apresentados como média $\pm$ desvio padrão ao longo dos 10 *folds*, com o melhor resultado de cada métrica destacado em negrito

Modelo	MSE [10^{16} US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
<i>XGBoost Regressor</i>	1,39 $\pm$ 0,31	117,32 $\pm$ 12,95	58,94 $\pm$ 2,49	0,594 $\pm$ 0,060
<i>Random Forest Regressor</i>	1,44 $\pm$ 0,30	119,31 $\pm$ 12,50	59,53 $\pm$ 2,33	0,579 $\pm$ 0,068
<i>Gradient Boosting Regressor</i>	1,46 $\pm$ 0,32	120,15 $\pm$ 12,87	59,19 $\pm$ 2,67	0,571 $\pm$ 0,086
<i>Linear Regression</i>	1,51 $\pm$ 0,36	122,18 $\pm$ 14,59	63,63 $\pm$ 2,56	0,562 $\pm$ 0,054
<i>Decision Tree Regressor</i>	1,71 $\pm$ 0,32	130,44 $\pm$ 12,01	64,03 $\pm$ 1,94	0,494 $\pm$ 0,097
<i>KNN Regressor</i>	1,73 $\pm$ 0,36	130,87 $\pm$ 13,85	66,96 $\pm$ 3,60	0,497 $\pm$ 0,057
<i>Dummy Regressor</i>	3,45 $\pm$ 0,68	184,99 $\pm$ 18,95	104,67 $\pm$ 3,15	0,000 $\pm$ 0,001
<i>SVR</i>	3,86 $\pm$ 0,71	195,71 $\pm$ 18,74	86,55 $\pm$ 3,11	-0,121 $\pm$ 0,018

Tabela 4. Métricas do *XGBoost Regressor* sem transformação da variável-alvo por faixa de receita. Os intervalos seguem os mesmos cortes utilizados na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]	26,50	-26,23	7,4%
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]	32,40	-31,14	11,1%
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]	31,00	-23,51	28,4%
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]	41,33	-2,60	59,0%
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	163,44	83,54	71,7%

com receitas muito baixas ou muito elevadas.

**Figura 9.** Valores reais versus previstos por faixa de receita para o *XGBoost Regressor*

A Figura 9 reforça visualmente o padrão observado na Tabela 4. A linha tracejada representa o cenário ideal, em que a receita prevista seria igual à receita real. Observa-se que, nas faixas de menor receita, muitos pontos ficam acima dessa linha, confirmando a tendência de superestimação indicada pelos resíduos médios negativos. Nas faixas superiores, especialmente entre os filmes de maior arrecadação, os pontos se tornam mais dispersos e passam a aparecer com maior frequência abaixo da diagonal, o que confirma a maior dificuldade do modelo em acompanhar os casos extremos da distribuição.

Esses resultados respondem à QP3 ao mostrar que o erro não é homogêneo ao longo das faixas de receita. O modelo tende a superestimar filmes de baixa arrecadação, apresenta comportamento mais equilibrado em faixas intermediárias e passa a subestimar com maior frequência os filmes de receita mais alta. Assim, a principal limitação da abordagem está na dificuldade de representar adequadamente os casos extremos

da cauda superior, comportamento que também não foi totalmente resolvido nos experimentos complementares com transformação logarítmica da variável-alvo, apresentados no Apêndice A.

5.3 Importância dos atributos

Para interpretar quais atributos sustentaram o desempenho do melhor modelo nos experimentos sem transformação da variável-alvo, foi calculada a importância por permutação do *XGBoost Regressor*. Como descrito na Subseção 4.6, essa técnica avalia quanto o erro do modelo aumenta quando os valores de cada atributo são embaralhados no conjunto de teste. Neste trabalho, a variação foi medida a partir do erro quadrático médio, de modo que maiores aumentos no erro indicam maior relevância do atributo para as predições.

A Figura 10 mostra que a importância dos atributos é bastante concentrada. O orçamento aparece como o atributo mais relevante, com diferença expressiva em relação aos demais. Em seguida, destacam-se o pertencimento a uma coleção e a duração do filme, indicando que características associadas à escala de produção, ao vínculo com franquias e à estrutura da obra tiveram papel importante nas estimativas do modelo. Esses três atributos se sobressaem em relação aos demais, sugerindo que grande parte da capacidade preditiva do modelo está apoiada em variáveis estruturais diretamente relacionadas à caracterização inicial dos filmes.

Além desses atributos principais, algumas categorias de gênero e idioma original também aparecem com importância positiva, como animação, ficção científica, romance e o idioma inglês. No entanto, essas variáveis apresentam contribuição mais distribuída e menos dominante, o que indica que ajudam a complementar a predição, mas não sustentam o desempenho do modelo no mesmo nível que orçamento, coleção e duração. Também aparecem importâncias médias negativas em alguns atributos. Esses valores não significam que tais características reduzem a receita dos filmes, mas apenas que, nesse experimento, embaralhar esses atributos não aumentou o erro do modelo de forma consistente, sugerindo




Figura 10. Importância média dos atributos por permutação para o *XGBoost Regressor* sem transformação da variável-alvo

contribuição fraca, redundante ou instável para as predições.

Dessa forma, a QP4 é respondida ao indicar que orçamento, pertencimento a uma coleção e duração figuram entre os atributos mais relevantes para a predição da receita. Em termos interpretativos, o orçamento pode refletir a escala de produção e o nível de investimento associado ao filme, enquanto o pertencimento a uma coleção pode indicar reconhecimento prévio da franquia, público já estabelecido e maior expectativa de arrecadação. A duração, por sua vez, aparece como uma característica estrutural da obra, contribuindo em menor grau, mas ainda de forma relevante. Já variáveis categóricas, como gênero e idioma original, complementam a predição com influência mais distribuída entre diferentes categorias.

6 Conclusão

Este trabalho apresentou uma análise comparativa de modelos de regressão para a predição da receita mundial de filmes a partir de metadados estruturados extraídos da API pública do TMDb. Foram considerados atributos como orçamento, duração, idioma original, gêneros e pertencimento a uma coleção, com o objetivo de avaliar o potencial dessas informações para estimar o desempenho comercial das obras em fases iniciais de planejamento.

Os resultados mostraram que os metadados estruturados utilizados possuem capacidade preditiva parcial. Nos experimentos sem transformação da variável-alvo, o melhor desempenho global foi obtido pelo *XGBoost Regressor*, que apresentou os menores valores de MSE, RMSE e MAE e o maior valor de R^2 . De modo geral, os modelos de *ensemble* baseados em árvores apresentaram desempenho superior aos modelos mais simples.

A análise dos erros por faixa de receita indicou que o desempenho do modelo não é homogêneo ao longo da distribuição da variável-alvo. O modelo tende a superestimar filmes de menor arrecadação e a subestimar filmes de maior receita, concentrando seus maiores erros nos filmes de arrecadação muito alta. A análise de importância dos atributos indicou orçamento, pertencimento a uma coleção e duração como as variáveis mais relevantes para a predição.

Como análise complementar, os experimentos com transformação logarítmica da variável-alvo indicaram redução do MAE em alguns modelos, mas não alteraram a conclusão geral do estudo, uma vez que os melhores valores de RMSE e R^2 permaneceram associados aos experimentos sem transformação da variável-alvo. Além disso, a investigação

do SVR indicou que seu desempenho inferior ao *Dummy Regressor* em RMSE e R^2 esteve associado à forte assimetria da receita e à produção de predições concentradas em valores centrais da distribuição da receita.

Como trabalhos futuros, pretende-se ampliar o conjunto de atributos utilizados, incorporando informações como elenco, diretor, distribuidora, período de estreia e sinais externos de interesse do público em plataformas *online*. Também podem ser investigadas estratégias específicas para lidar com a assimetria da receita, como modelos por faixas de arrecadação, funções de perda mais robustas ou abordagens híbridas que combinem classificação e regressão.

Declarações complementares

Contribuições dos autores

Sob orientação do docente responsável pela disciplina de Aprendizado de Máquina, o autor foi responsável pela concepção do estudo, preparação dos dados, definição da metodologia, implementação dos experimentos, análise dos resultados e escrita, revisão e edição do manuscrito.

Conflitos de interesse

O autor declara que não possui conflitos de interesse.

Disponibilidade de dados e materiais

Os conjuntos de dados analisados e os códigos-fonte desenvolvidos durante o estudo atual estão disponíveis em: github.com/gabrielprenassi/UFSJ_Aprendizado_Maquina_TP1.

Referências

- Abidi, S. M. R., Xu, Y., Ni, J., Wang, X., and Zhang, W. (2020). Popularity prediction of movies: from statistical modeling to machine learning techniques. *Multimedia Tools and Applications*, 79(47):35583–35617.
- Ahmad, I. S., Bakar, A. A., and Yaakub, M. R. (2020a). Movie revenue prediction based on purchase intention mining using youtube trailer reviews. *Information Processing & Management*, 57(5):102278.
- Ahmad, I. S., Bakar, A. A., Yaakub, M. R., and Muhammad, S. H. (2020b). A survey on machine learning techniques in movie revenue prediction. *SN Computer Science*, 1(4):235.
- Ghiassi, M., Lio, D., and Moon, B. (2015). Pre-production forecasting of movie revenues with a dynamic artificial neural network. *Expert Systems with Applications*, 42(6):3176–3193.
- Gupta, V., Jain, N., Garg, H., Jhunthra, S., Mohan, S., Omar, A. H., and Ahmadian, A. (2023). Predicting attributes based movie success through ensemble machine learning. *Multimedia Tools and Applications*, 82(7):9597–9626.
- James, G., Witten, D., Hastie, T., Tibshirani, R., and Taylor, J. (2023). Statistical learning. In *An introduction to statistical learning: With applications in Python*, pages 15–67. Springer.
- Kim, T., Hong, J., and Kang, P. (2015). Box office forecasting using machine learning algorithms based on sns data. *International Journal of Forecasting*, 31(2):364–390.
- Lash, M. T. and Zhao, K. (2016). Early predictions of movie success: The who, what, and when of profitability. *Journal of Management Information Systems*, 33(3):874–903.

- Madongo, C. T. and Zhongjun, T. (2023). A movie box office revenue prediction model based on deep multimodal features. *Multimedia Tools and Applications*, 82(21):31981–32009.
- Mammadov, S., Abdulrashid, I., Khalafalla, M., and Delen, D. (2025). Identifying factors influencing box-office success of motion pictures with xai. *Journal of Computer Information Systems*, pages 1–17.
- Murphy, K. P. (2022). *Probabilistic machine learning: an introduction*. MIT press.
- Quader, N., Gani, M. O., Chaki, D., and Ali, M. H. (2017). A machine learning approach to predict movie box-office success. In *2017 20th International Conference of Computer and Information Technology (ICCIT)*, pages 1–7. IEEE.
- Sharda, R. and Delen, D. (2006). Predicting box-office success of motion pictures with neural networks. *Expert Systems with Applications*, 30(2):243–254.
- Udandara, V. and Gupta, P. (2024). Movie revenue prediction using machine learning models. *arXiv preprint arXiv:2405.11651*.
- Zhou, Y., Zhang, L., and Yi, Z. (2019). Predicting movie box-office revenues using deep neural networks. *Neural Computing and Applications*, 31(6):1855–1865.

A Experimentos complementares com transformação logarítmica da variável-alvo

Como análise complementar, foram avaliados modelos treinados com transformação logarítmica da variável-alvo. Essa avaliação foi motivada pela forte assimetria da receita, discutida na Subseção 4.3, marcada pela concentração de muitos filmes em faixas mais baixas de arrecadação e pela presença de poucos títulos com receitas muito elevadas. Nos experimentos, a receita foi transformada por meio de $\log(1 + \text{receita})$ durante o treinamento, e as predições foram posteriormente reconvertidas para a escala original antes do cálculo das métricas finais. Dessa forma, os resultados permaneceram comparáveis aos experimentos sem transformação da variável-alvo.

A.1 Comparação global entre os modelos

A Tabela 5 apresenta o desempenho médio dos modelos treinados com transformação logarítmica da variável-alvo. Nessa avaliação, o *Random Forest Regressor* obteve o melhor desempenho em MSE, RMSE e R^2 , com MSE médio de $1,52 \times 10^{16}$ US\$², RMSE médio de US\$ 122,50 milhões e $R^2 = 0,560$. O menor MAE, por pequena diferença, foi obtido pelo *XGBoost Regressor*, com US\$ 55,62 milhões.

Em comparação com os experimentos sem transformação da variável-alvo, a transformação logarítmica trouxe ganhos localizados, mas não alterou a conclusão geral do estudo. Embora tenha reduzido o MAE em alguns modelos, indicando menor erro absoluto médio, ela não levou aos melhores resultados em RMSE e R^2 . Esses valores permaneceram associados ao *XGBoost Regressor* treinado diretamente sobre a receita em sua escala original, com RMSE de US\$ 117,32 milhões e $R^2 = 0,594$. Assim, o melhor desempenho global do estudo permaneceu associado ao *XGBoost Regressor* sem transformação da variável-alvo.

Esse comportamento pode ser explicado pelo efeito da transformação logarítmica sobre a cauda superior da distribuição. Ao comprimir valores muito elevados durante o treinamento, a transformação reduz a influência dos filmes de arrecadação extrema e favorece a aproximação de casos mais frequentes da base. No entanto, como as métricas finais foram calculadas após a reconversão das predições para dólares, erros em filmes de alta arrecadação continuaram tendo grande impacto sobre medidas sensíveis a grandes desvios, como RMSE e R^2 . Dessa forma, a transformação ajudou em parte da distribuição, mas não resolveu a principal dificuldade do problema.

Além disso, a Tabela 5 mostra que a transformação logarítmica não afetou todos os modelos da mesma forma. A *Linear Regression*, que sem transformação havia obtido desempenho competitivo, apresentou deterioração acentuada com a variável-alvo transformada, alcançando RMSE médio de US\$ 4,28 bilhões e R^2 médio de $-1186,466$, além de desvios padrão muito elevados entre os *folds*. Esse contraste sugere que a relação entre os preditores e a receita não foi bem representada por uma estrutura linear no espaço logarítmico, levando a predições muito distantes dos valores reais após a reconversão para dólares.

A.2 Análise dos erros por faixa de receita

Assim como na análise principal, a avaliação por faixa de receita utilizou os mesmos cortes definidos na estratificação dos *folds*. Essa análise permite observar se os efeitos da transformação logarítmica se distribuem de forma homogênea ao longo da receita ou se ficam concentrados em determinadas regiões da variável-alvo.

Os resultados da Tabela 6 indicam que a transformação logarítmica foi mais favorável nas faixas de menor arrecadação. O MAE foi de US\$ 10,80 milhões na faixa muito baixa e de US\$ 15,03 milhões na faixa baixa, valores inferiores aos observados nos experimentos sem transformação da variável-alvo. Esse comportamento sugere que a compressão da escala ajudou o modelo a reduzir erros em casos mais frequentes da base.

Nas faixas superiores, porém, observa-se aumento da tendência de subestimação. Na faixa alta, 79,0% dos filmes foram subestimados, e, na faixa muito alta, esse percentual chegou a 82,5%, com resíduo médio de US\$ 134,15 milhões. Assim, a transformação logarítmica tornou o modelo mais conservador para filmes de maior arrecadação. Esse resultado ajuda a explicar por que houve melhora em MAE em parte da distribuição, mas não superação dos melhores resultados em RMSE e R^2 , que continuam mais sensíveis aos grandes desvios na cauda superior.

A.3 Importância por permutação

Como análise adicional, foi calculada a importância por permutação para o *Random Forest Regressor* treinado com transformação logarítmica da variável-alvo, utilizando o MSE como métrica de avaliação. Essa etapa permite verificar se a configuração com $\log(1 + \text{receita})$ altera de forma relevante a leitura sobre os atributos usados pelo modelo.


A Figura 11 mostra quais atributos mais influenciaram as predições do *Random Forest Regressor* com transformação logarítmica da variável-alvo. Em comparação com os

Tabela 5. Desempenho dos modelos com transformação logarítmica da variável-alvo, ordenados por RMSE. Os valores são apresentados como média $\pm$ desvio padrão ao longo dos 10 *folds*, com o melhor resultado de cada métrica destacado em negrito

Modelo	MSE [10^{16} US\$ ²]	RMSE [US\$ mi]	MAE [US\$ mi]	R^2
<i>Random Forest Regressor</i>	1,52 $\pm$ 0,35	122,50 $\pm$ 14,44	55,68 $\pm$ 2,47	0,560 $\pm$ 0,049
<i>XGBoost Regressor</i>	1,59 $\pm$ 0,43	124,87 $\pm$ 17,08	55,62 $\pm$ 2,94	0,545 $\pm$ 0,050
<i>Gradient Boosting Regressor</i>	1,66 $\pm$ 0,47	127,55 $\pm$ 18,30	56,33 $\pm$ 3,01	0,525 $\pm$ 0,061
<i>Decision Tree Regressor</i>	1,69 $\pm$ 0,35	129,47 $\pm$ 13,37	60,31 $\pm$ 2,32	0,506 $\pm$ 0,063
<i>KNN Regressor</i>	2,08 $\pm$ 0,46	143,27 $\pm$ 16,76	64,28 $\pm$ 2,87	0,400 $\pm$ 0,053
<i>SVR</i>	3,16 $\pm$ 1,38	174,03 $\pm$ 38,70	66,25 $\pm$ 5,67	0,052 $\pm$ 0,456
<i>Dummy Regressor</i>	3,97 $\pm$ 0,71	198,45 $\pm$ 18,58	87,04 $\pm$ 3,06	-0,153 $\pm$ 0,024
<i>Linear Regression</i>	4670,00 $\pm$ 9920,00	4284,38 $\pm$ 5615,12	260,40 $\pm$ 232,61	-1186,466 $\pm$ 2411,346

Tabela 6. Métricas do *Random Forest Regressor* com transformação logarítmica da variável-alvo por faixa de receita. Os intervalos seguem os mesmos cortes utilizados na estratificação da validação cruzada

Faixa de receita	Qtd.	Intervalo de receita	MAE [US\$ mi]	Resíduo médio [US\$ mi]	Subest.
Muito baixa receita	1384	[US\$ 1, US\$ 7,09 mi]	10,80	-10,33	14,0%
Baixa receita	1383	(US\$ 7,09 mi, US\$ 22,46 mi]	15,03	-9,86	39,0%
Média receita	1384	(US\$ 22,46 mi, US\$ 52,82 mi]	22,73	0,80	63,4%
Alta receita	1383	(US\$ 52,82 mi, US\$ 134,08 mi]	47,08	27,23	79,0%
Muito alta receita	1384	(US\$ 134,08 mi, US\$ 2.923,71 mi]	182,69	134,15	82,5%

**Figura 11.** Importância média dos atributos por permutação para o *Random Forest Regressor* com transformação logarítmica da variável-alvo

experimentos sem transformação, a importância dos atributos permaneceu concentrada em variáveis estruturais, como orçamento, pertencimento a uma coleção e duração. Assim, embora a transformação logarítmica tenha modificado o comportamento dos erros em diferentes faixas de receita, a interpretação sobre os atributos mais relevantes para as predições permaneceu semelhante.

B Investigação do desempenho do SVR sem transformação da variável-alvo

Este apêndice complementa a discussão dos resultados com uma análise específica do desempenho do SVR nos experimentos sem transformação da variável-alvo. Como mostrado na Tabela 3, o SVR obteve RMSE médio de US\$ 195,71 milhões, MAE médio de US\$ 86,55 milhões e R^2 médio de -0,121, enquanto o *Dummy Regressor* registrou RMSE médio de US\$ 184,99 milhões, MAE médio de US\$ 104,67 milhões e R^2 próximo de zero. Portanto, o SVR não foi inferior em todas as métricas, mas teve pior desempenho justamente nas medidas mais sensíveis a erros de grande magnitude.

Esse comportamento está relacionado à distribuição da receita. Como observado na Subseção 4.3, a variável-alvo

apresenta forte assimetria à direita, com muitos filmes concentrados em faixas baixas ou intermediárias de arrecadação e poucos títulos com receitas extremamente elevadas. Nesse cenário, o SVR apresentou predições com baixa variabilidade e concentradas em torno de valores centrais da distribuição. Isso ajuda a explicar o MAE menor que o do *Dummy Regressor*, pois muitos filmes da base estão mais próximos dessa região central do que de valores muito elevados de arrecadação. No entanto, para filmes de arrecadação muito alta, essa concentração gerou desvios elevados, aumentando o RMSE e reduzindo o R^2 . Isso ocorre porque o MAE considera os desvios de forma linear, enquanto RMSE e R^2 são mais afetados por erros extremos, por dependerem de desvios quadráticos.

A comparação com os experimentos com transformação logarítmica, apresentados na Tabela 5, reforça essa interpretação. Com $\log(1 + \text{receita})$, o SVR melhorou em relação à versão sem transformação, alcançando RMSE médio de US\$ 174,03 milhões, MAE médio de US\$ 66,25 milhões e R^2 médio de 0,052. Ainda assim, seu desempenho permaneceu abaixo dos melhores modelos de *ensemble*, indicando que a transformação reduziu parte da dificuldade enfrentada pelo modelo, mas não foi suficiente para torná-lo competitivo com os melhores regressores avaliados.

Em síntese, o desempenho limitado do SVR nos experimentos sem transformação da variável-alvo não indica ausência de informação nas variáveis explicativas, mas sim dificuldade do modelo em lidar diretamente com uma variável-alvo muito assimétrica e com valores extremos. Assim, o modelo apresentou comportamento relativamente melhor em termos de erro absoluto médio, mas falhou nos casos de arrecadação muito elevada, prejudicando principalmente RMSE e R^2 .